client 응답 시간

retrieval_a(기존 · Qdrant) / retrieval_b · 측정 2026-11-12 12:13 ~ 12:29

1. 무엇을 쟀나

- **client와 같은 경로**: 사전 판단 LLM → 검색 → 답변 LLM → 사후 검사(규칙). 웹 화면·API가 쓰는 서비스 체인 그대로입니다.
- **측정 환경 ① 로컬** (2~4절): 내 PC가 서비스 체인을 직접 실행하고 임베딩·리랭커 모델을 내 PC GPU(노트북 RTX 5060)에 새로 불러옵니다. 문서는 팀 Qdrant, LLM은 OpenAI. 서버를 막 켠 상태를 가정해 구성 × 난이도마다 새 프로세스에서 잽니다. 세 구성을 모두 잴 수 있습니다.
- **측정 환경 ② 팀 서버** (5절): 팀 서버 API(/query)로 서버에 이미 올라가 있는 모델·검색 자원을 그대로 씁니다. 서버 구현은 retrieval_a(기존 방식) 하나라 A · 기존만 잴 수 있습니다.
- 방식마다 naive → hybrid → hybrid + rerank 순서로 질문 두 개를 보냅니다. **첫 번째 질문**에는 그 방식을 처음 쓸 때의 준비(모델·청크 로딩)가 들어가고, **두 번째 질문**은 준비가 끝난 뒤 시간입니다.
- 답변 모델 gpt-6-luna (서버와 같음). 질문은 각 난이도 development의 첫 두 문항. 조합마다 한 번씩 잰 값이라 LLM 속도에 따라 ±2초 쯤 흔들릴 수 있습니다.

2. 로컬 측정 결과 (초): 첫 번째 / 두 번째 질문

난이도	구성	naive	hybrid	hybrid + rerank
basic	A · 기존	20.3 / 6.1	11.4 / 7.6	9.0 / 8.1
basic	A · Qdrant	20.9 / 8.2	9.3 / 8.2	9.2 / 8.8
basic	B	16.7 / 6.7	8.1 / 7.4	9.7 / 8.8
intermediate	A · 기존	15.5 / 6.5	43.3 / 6.6	9.3 / 9.5
intermediate	A · Qdrant	16.3 / 6.8	8.0 / 8.1	9.3 / 9.1
intermediate	B	15.8 / 8.9	24.0 / 7.5	10.0 / 9.2
advanced	A · 기존	15.3 / 7.2	232 (3분 52초) / 9.3	9.8 / 10.8
advanced	A · Qdrant	15.1 / 7.2	8.2 / 7.4	9.3 / 9.6
advanced	B	15.7 / 7.0	111 (1분 51초) / 11.9	10.0 / 11.9

노란 줄 = 첫 질문이 30초를 넘는 조합. 오류는 54번 중 0건입니다.

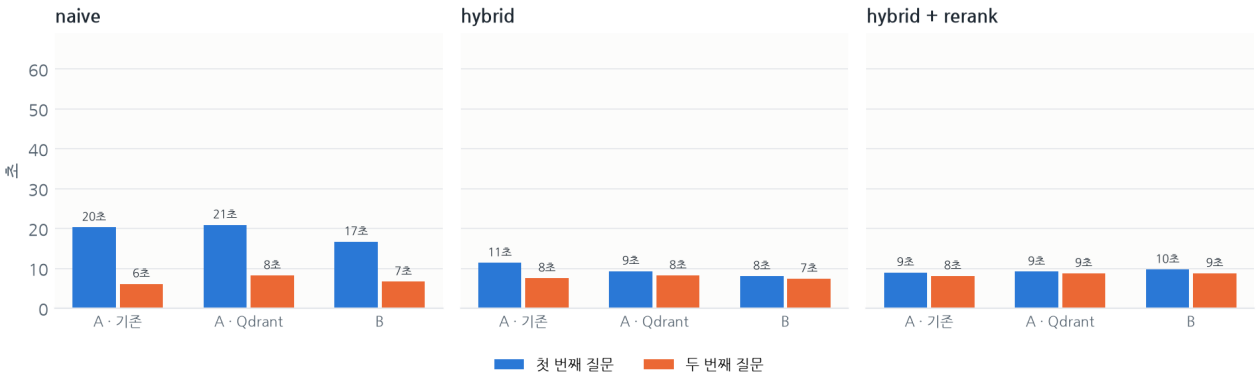
3. 무엇이 시간을 쓰나

상황	늘어나는 시간	원인
어떤 방식이든 서버에서 처음 쓸 때	+8~14초 (naive 첫 질문 15~21초)	임베딩 모델·LLM 클라이언트 로딩
A · 기존 hybrid를 처음 쓸 때	intermediate +37초, advanced +3.7분	청크와 벡터를 Qdrant에서 통째로 받음
B hybrid를 처음 쓸 때	intermediate +17초, advanced +1.7분	BM25용 청크를 통째로 받음
A · Qdrant hybrid를 처음 쓸 때	거의 0초	받아 올 것이 없음 (질문마다 Qdrant에 후보만 물음)
두 번째 질문부터 (모든 구성)	naive 6~9초, rerank 8~12초	대부분 LLM 두 번(사전 판단 + 답변). 검색 자체는 1초 미만

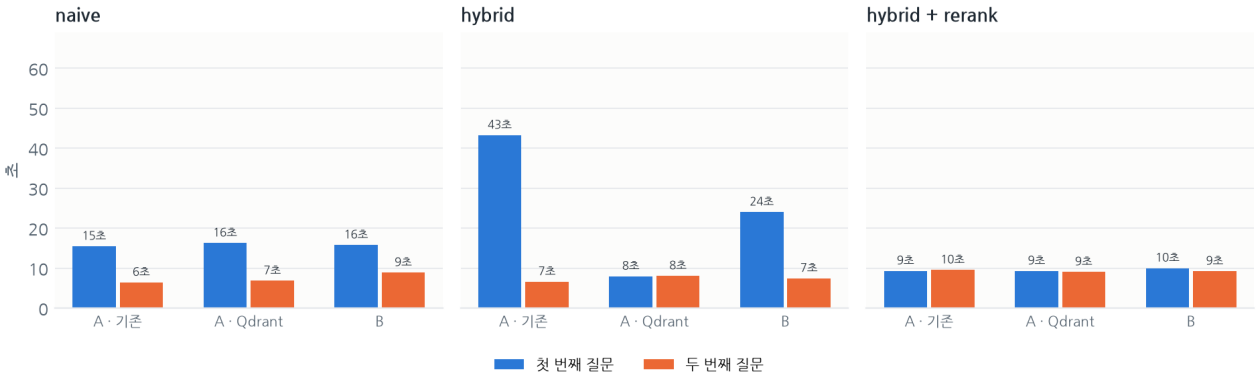
주의 hybrid + rerank의 첫 질문이 짧은 것은 측정 순서상 hybrid 준비가 이미 끝나 있었기 때문입니다. 사용자가 hybrid + rerank를 맨 처음 고르면 hybrid 첫 질문 시간이 그대로 더해집니다(예: advanced A · 기존 약 4분). 실제 팀 서버(main.py)는 시작할 때 세 난이도의 검색 자원을 미리 준비(워밍업)하므로 사용자는 대부분 두 번째 질문 시간을 겪고, 대신 서버 시작이 그만큼 늦어집니다.

4. 난이도별 차트 (로컬)

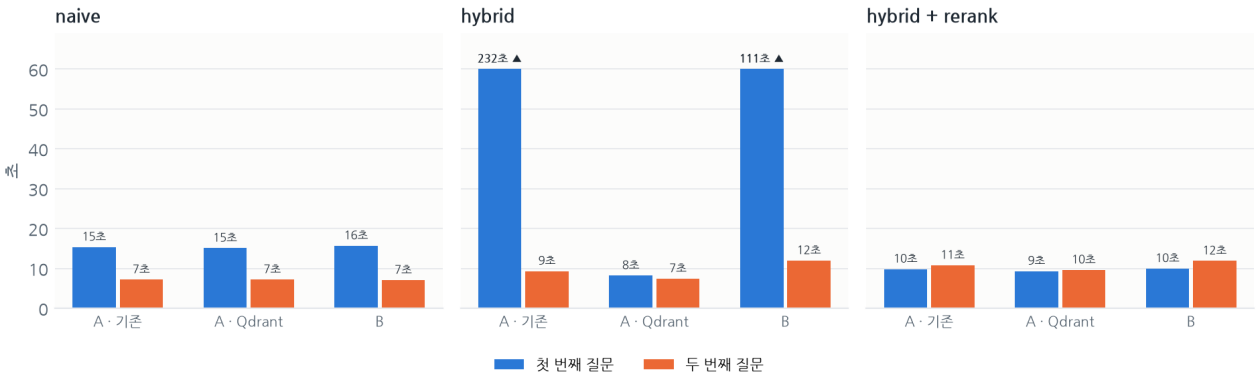
basic



intermediate



advanced



축은 60초에서 잘랐습니다. ▲ 표시는 실제 값이 그보다 큰 막대입니다.

5. 팀 서버 측정 (서버에 올라간 모델 사용, retrieval_a)

측정 12:44 ~ 12:46 · 18번 중 오류 0번 · 서버 처리 시간(elapsed)과 왕복 시간 차이 0.1초 이하

난이도	방식	질문 1 (서버)	질문 2 (서버)	질문 1 (로컬 A · 기존)	질문 2 (로컬 A · 기존)
basic	naive	4.7	8.9	20.3	6.1
basic	hybrid	3.4	6.0	11.4	7.6
basic	hybrid + rerank	4.5	8.8	9.0	8.1
intermediate	naive	4.4	7.6	15.5	6.5
intermediate	hybrid	4.3	6.8	43.3	6.6
intermediate	hybrid + rerank	3.9	8.9	9.3	9.5
advanced	naive	4.3	8.0	15.3	7.2
advanced	hybrid	3.9	7.5	232 (3분 52초)	9.3
advanced	hybrid + rerank	4.5	10.3	9.8	10.8

- 서버는 시작할 때 세 난이도의 검색 자원을 미리 준비해 두어 **질문 1에도 로딩 대기가 없습니다**. 로컬의 첫 번째 질문(15초 ~ 4분)은 내 PC에서 모델과 청크를 처음 불러오는 시간이 섞인 값입니다.
- 서버에서 질문 1(약 4초)과 질문 2(6~10초)의 차이는 로딩이 아니라 **질문 내용** 때문입니다. 질문 2는 답이 길거나 되묻기로 처리된 경우가 많았습니다. 질문 2끼리 보면 서버와 로컬이 비슷해, 로컬의 두 번째 질문 시간이 실제 서버 체감과 가깝습니다.
- 실제 사용자가 겪는 시간 ≈ 서버 측정값: 질문에 따라 약 3~10초이고, 대부분 LLM 두 번(사전 판단 + 답변)에 쓰입니다.

6. 서버에서 질문 2가 더 오래 걸리는 이유

측정에 넣은 질문 (각 난이도 development의 첫 두 문항)

난이도	순서	문항 ID	질문 (측정에 넣은 원문)	정답 파일의 기대 동작
basic	질문 1	S-DEV-01	가온루트해운 부산-LA 안내에서 일반 건화물로 예약할 수 있는 컨테이너 종류는 무엇인가요?	답변
basic	질문 2	S-DEV-02	가온루트 부산-LA 일반 건화물 40GP로 2026년 11월 6일 출항을 처음 신청하려고 합니다. 예약 메일에 넣을 정보와 창구, 그 일정으로 예약이 확정됐을 때 준비할 SI 마감과 제출처를 한 번에 정리해 주세요.	답변
intermediate	질문 1	IS-DEV-01	가온루트해운 부산-LA 안내에서 일반 건화물로 예약할 수 있는 컨테이너 종류는 무엇인가요?	답변
intermediate	질문 2	IS-DEV-02	가온루트 부산-LA 일반 건화물 40GP로 2026년 11월 6일 출항을 처음 신청하려고 합니다. 예약 메일에 넣을 정보와 창구, 그 일정으로 예약이 확정됐을 때 준비할 SI 마감과 제출처를 한 번에 정리해 주세요.	답변
advanced	질문 1	AS-DEV01	가온루트해운 부산-LA 안내에서 일반 건화물로 예약할 수 있는 컨테이너 종류는 무엇인가요?	답변
advanced	질문 2	AS-DEV02	가온루트 부산-LA 일반 건화물 40GP로 2026년 11월 6일 출항을 처음 신청하려고 합니다. 예약 메일에 넣을 정보와 창구, 그 일정으로 예약이 확정됐을 때 준비할 SI 마감과 제출처를 한 번에 정리해 주세요.	답변

질문 1 vs 질문 2 (서버, hybrid + rerank)

원인 확인용으로 12:53에 같은 질문을 서버에 다시 보내 하위 질문·문맥·답변 길이를 기록했습니다(5절 측정과 별도 실행이라 시간은 조금 다릅니다).

난이도	질문	묻는 내용	하위 질문	검색 횟수	답변에 넣은 문맥	답변 길이	응답 상태	시간(초)
basic	질문 1	한 가지	0개	1번	5개	69자	답변	4.9
basic	질문 2	여러 가지	3개	4번	12개	500자	답변	9.7
intermediate	질문 1	한 가지	0개	1번	5개	59자	답변	5.0
intermediate	질문 2	여러 가지	3개	4번	12개	400자	되묻기	11.7
advanced	질문 1	한 가지	0개	1번	5개	101자	답변	5.3
advanced	질문 2	여러 가지	3개	4번	12개	408자	되묻기	13.9

결론 질문 2는 모두 **여러 가지를 한 번에 묻는 복합 질문**이라 서비스의 사전 판단 LLM이 하위 질문 3개로 쪼갭니다. 그래서 검색을 4번 하고, 결과를 합쳐 답변에 문맥을 약 12개(질문 1은 5개) 넣고, 답도 약 4~7배 길게 씁니다. 평균 시간 질문 1 5.0초 → 질문 2 11.7초. 로딩과는 관계없습니다.

시간이 늘어나는 곳

단계	질문 2에서 하는 일	늘어나는 시간 (대략)
① **사전 판단 LLM**	검색 질문과 하위 질문 3개를 직접 써야 해서 출력이 길어짐	+1초 안팎
② **검색**	질문 4개를 각각 hybrid + rerank (리랭커도 4번)	+1~2초
③ **답변 LLM**	문맥 약 12개(입력 약 2배)를 읽고 400~500자 답을 씀. LLM은 답이 길수록 오래 걸림	+2~5초 (가장 큼)

예: basic 질문 2를 사전 판단이 쪼갠 하위 질문

- 가온루트 부산-LA 일반 건화물 40GP의 2026년 11월 6일 출항 예약을 처음 신청할 때 예약 메일에 기재할 정보는 무엇이며, 예약 신청 창구는 어디인가요?
- 가온루트 부산-LA 일반 건화물 40GP의 2026년 11월 6일 출항 예약이 확정된 경우 SI 마감은 언제인가요?
- 가온루트 부산-LA 일반 건화물 40GP의 2026년 11월 6일 출항 예약이 확정된 경우 SI 제출처는 어디인가요?

- 되묻기(needs_clarification)도 무엇이 부족한지 설명을 써야 해서 답변과 비슷하게 시간이 걸립니다.
- 평가 실험(langfuse_experiment.py)은 질문을 쪼개지 않아 복합 질문도 문맥 5개로 답합니다. 그래서 평가의 응답 시간(중앙값 약 4초)이 서비스보다 짧습니다.
- 차이를 줄이려면 config/generation/rag.yaml의 max_sub_questions(3)나 max_docs(12)를 줄일 수 있지만, 복합 질문의 답이 덜 완전해질 수 있어 평가로 확인해야 합니다.
- 실제 체감 시간: **단일 질문 약 4~5초, 복합 질문 약 8~14초**.