RAGAS 평가 결과

retrieval_a (기존 · Qdrant) / retrieval_b · 골든 데이터셋 192문항 · 답변 1,536건 · 수집 2026-11-12 15:42

1. RAGAS 4지표

지표	묻는 것	계산	정답 사용
Faithfulness	답변이 문맥에 있는 내용만 말했나	답변을 짧은 주장들로 나누고, 각 주장이 실제 최종 문맥에서 확인되는 비율	안 씀
Answer Relevancy	질문에 맞는 답인가	답변으로 질문을 거꾸로 만들어 원래 질문과 얼마나 비슷한지 (임베딩 유사도)	안 씀
Context Precision	쓸모 있는 문맥이 위쪽에 있나	문맥마다 참고 정답에 도움이 되는지 판정하고, 위쪽일수록 큰 가중치	씀
Context Recall	정답에 필요한 내용을 문맥이 담았나	참고 정답을 주장들로 나누고, 각 주장이 문맥에서 확인되는 비율	씀

- ragas 0.4.3 라이브러리로 코드에서 계산했습니다(팀 채점 코드 evaluation/answer/quality.py). Faithfulness는 RAGAS 공식 예제대로 질문 → user_input, 생성 답변 → response, 실제 최종 문맥 → retrieved_contexts.
- 채점 모델 gpt-6-luna, Answer Relevancy의 유사도 계산은 bge-m3 임베딩. 세 구성에 같은 채점 모델·설정을 썼습니다.
- 채점 결과: 지표마다 1,536건 / 1,536건 채점, 평가 불가 0건 (일시적 채점 호출 실패 221건은 다시 채점함).
- 모두 0~1, 높을수록 좋습니다. 질문에 따라 1문항이 0.014~0.017이라 **0.03 안팎의 차이는 우연 범위**로 봅니다.

비교 구성

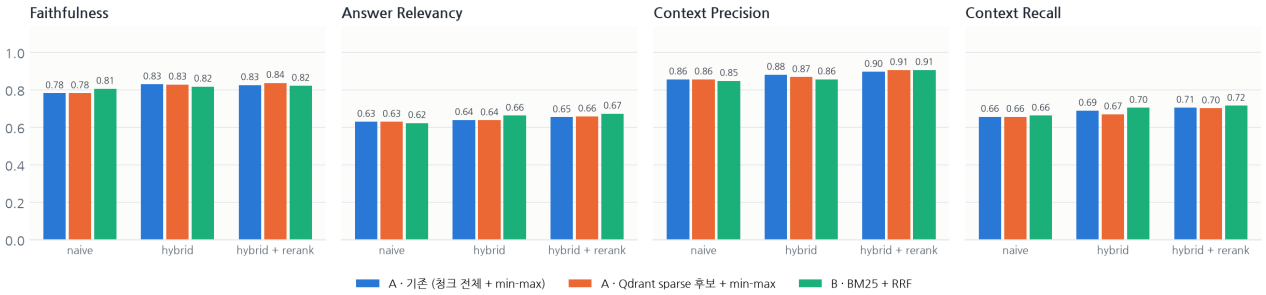
구성	sparse	점수 합치기	리랭커
A · 기존	bge-m3 sparse, 청크 전체에 직접 계산	전체 청크 min-max 0.7 : 0.3	bge-reranker-v2-m3, 후보 50
A · Qdrant	bge-m3 sparse, Qdrant 후보 100개 (실험 당시)	후보 안 min-max 0.7 : 0.3 (실험 당시)	bge-reranker-v2-m3, 후보 50
B	BM25 (Kiwi), 후보 30개	RRF (k = 60)	bge-reranker-v2-m3, 후보 50

세 구성 모두 같은 질문, 같은 답변 프롬프트와 생성 모델(gpt-6-luna), 같은 최종 문맥 수(k = 5)를 씁니다. naive는 sparse를 쓰지 않아 A · 기존과 A · Qdrant가 같은 실행입니다(※).

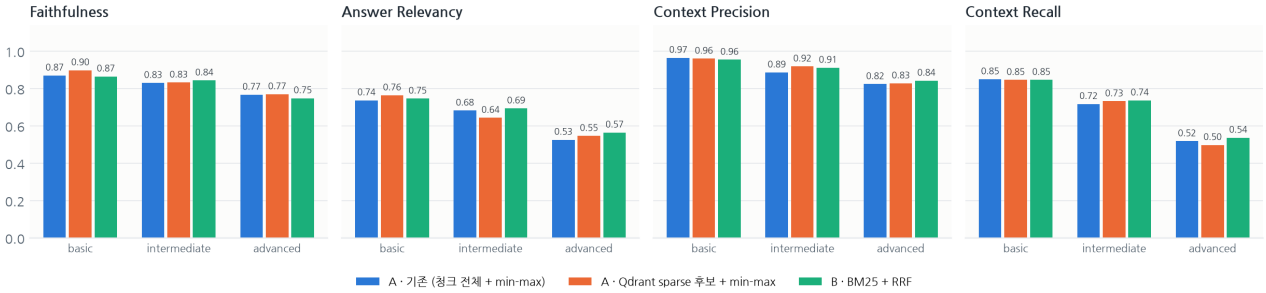
2. 192문항 전체

방식	구성	n	Faithfulness	Answer Relevancy	Context Precision	Context Recall
hybrid + rerank	A · 기존	192	0.826	0.655	0.897	0.706
hybrid + rerank	A · Qdrant	192	**0.838**	0.659	0.907	0.702
hybrid + rerank	B	192	0.823	**0.674**	**0.907**	**0.716**
hybrid	A · 기존	192	**0.830**	0.640	**0.881**	0.690
hybrid	A · Qdrant	192	0.830	0.639	0.869	0.670
hybrid	B	192	0.819	**0.663**	0.857	**0.705**
naive	A · 기존 ※	192	0.783	**0.630**	**0.857**	0.657
naive	A · Qdrant	192	0.783	**0.630**	**0.857**	0.657
naive	B	192	**0.806**	0.624	0.849	**0.663**

노란 줄 = 서비스 기본 방식(hybrid + rerank). 굵은 글씨 = 같은 방식 안에서 가장 높은 값.

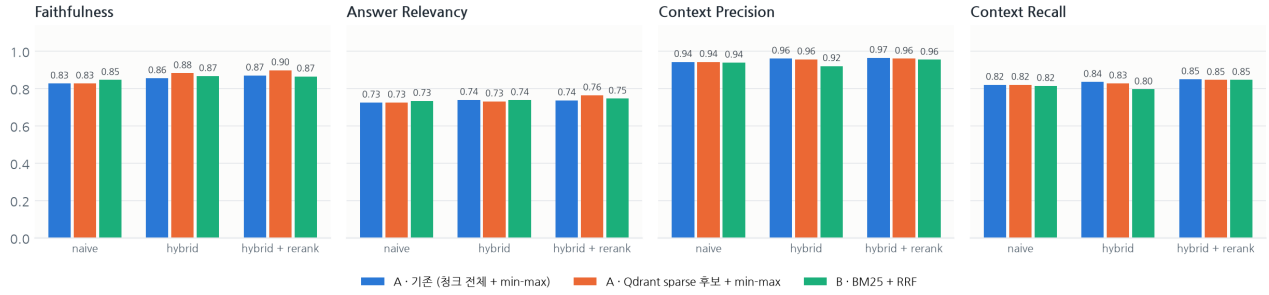


난이도별 (hybrid + rerank)



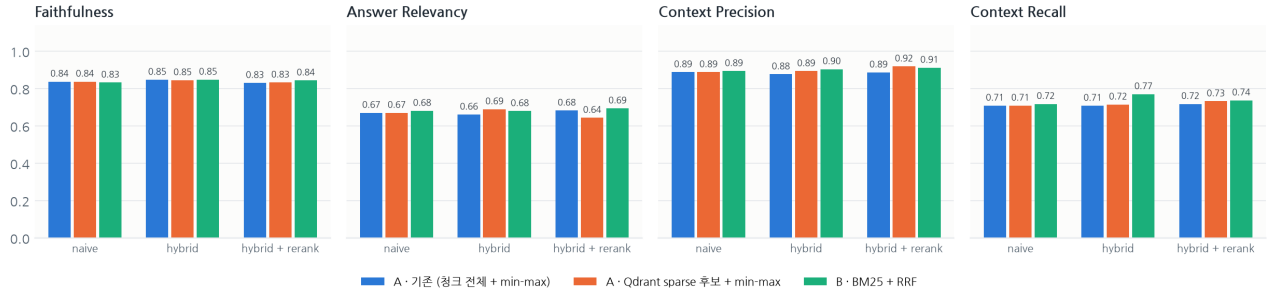
3. basic (72문항)

방식	구성	n	Faithfulness	Answer Relevancy	Context Precision	Context Recall
hybrid + rerank	A · 기존	72	0.871	0.738	**0.965**	**0.851**
hybrid + rerank	A · Qdrant	72	**0.899**	**0.764**	0.961	0.847
hybrid + rerank	B	72	0.866	0.747	0.955	0.847
hybrid	A · 기존	72	0.856	**0.740**	**0.962**	**0.836**
hybrid	A · Qdrant	72	**0.883**	0.732	0.957	0.829
hybrid	B	72	0.867	0.739	0.921	0.797
naive	A · 기존 ※	72	0.828	0.726	**0.944**	**0.821**
naive	A · Qdrant	72	0.828	0.726	**0.944**	**0.821**
naive	B	72	**0.847**	**0.735**	0.940	0.815



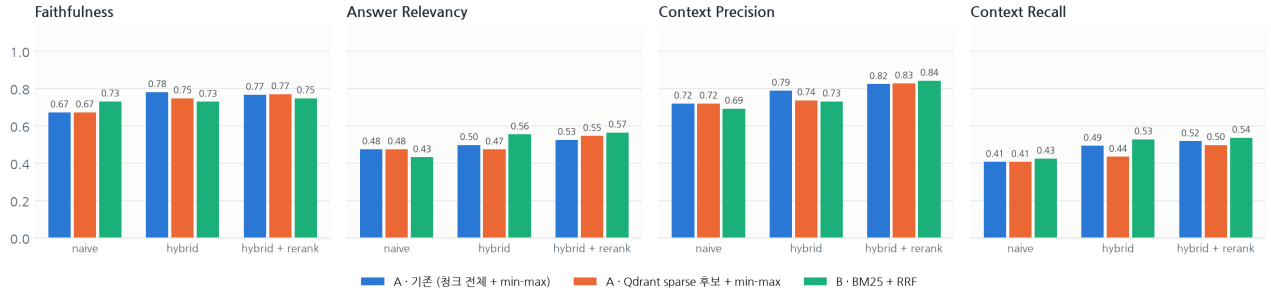
4. intermediate (60문항)

방식	구성	n	Faithfulness	Answer Relevancy	Context Precision	Context Recall
hybrid + rerank	A · 기존	60	0.831	0.683	0.887	0.718
hybrid + rerank	A · Qdrant	60	0.833	0.644	**0.919**	0.733
hybrid + rerank	B	60	**0.844**	**0.694**	0.912	**0.737**
hybrid	A · 기존	60	0.848	0.661	0.877	0.709
hybrid	A · Qdrant	60	0.846	**0.690**	0.894	0.715
hybrid	B	60	**0.849**	0.680	**0.905**	**0.771**
naive	A · 기존 ※	60	**0.838**	0.671	0.888	0.709
naive	A · Qdrant	60	**0.838**	0.671	0.888	0.709
naive	B	60	0.833	**0.682**	**0.894**	**0.718**



5. advanced (60문항)

방식	구성	n	Faithfulness	Answer Relevancy	Context Precision	Context Recall
hybrid + rerank	A · 기존	60	0.768	0.527	0.824	0.519
hybrid + rerank	A · Qdrant	60	**0.770**	0.547	0.828	0.498
hybrid + rerank	B	60	0.749	**0.566**	**0.843**	**0.538**
hybrid	A · 기존	60	**0.782**	0.498	**0.790**	0.494
hybrid	A · Qdrant	60	0.749	0.475	0.738	0.435
hybrid	B	60	0.730	**0.555**	0.732	**0.529**
naive	A · 기존 ※	60	0.674	**0.475**	**0.721**	0.408
naive	A · Qdrant	60	0.674	**0.475**	**0.721**	0.408
naive	B	60	**0.732**	0.433	0.694	**0.426**



6. 답변 상태별 (192문항, hybrid + rerank)

지표	구성	답변 평균 (건수)	되묻기 평균 (건수)	보류 평균 (건수)
Faithfulness	A · 기존	0.872 (116)	0.755 (49)	0.760 (27)
Faithfulness	A · Qdrant	0.885 (119)	0.731 (43)	0.806 (30)
Faithfulness	B	0.845 (124)	0.770 (38)	0.796 (30)
Answer Relevancy	A · 기존	0.791 (116)	0.464 (49)	0.414 (27)
Answer Relevancy	A · Qdrant	0.797 (119)	0.464 (43)	0.391 (30)
Answer Relevancy	B	0.788 (124)	0.562 (38)	0.346 (30)
Context Precision	A · 기존	0.952 (116)	0.816 (49)	0.806 (27)
Context Precision	A · Qdrant	0.954 (119)	0.849 (43)	0.801 (30)
Context Precision	B	0.950 (124)	0.874 (38)	0.769 (30)
Context Recall	A · 기존	0.853 (116)	0.518 (49)	0.414 (27)
Context Recall	A · Qdrant	0.836 (119)	0.481 (43)	0.487 (30)
Context Recall	B	0.835 (124)	0.494 (38)	0.507 (30)

되묻기와 보류는 사실 주장이 적고 질문에 직접 답하지 않아서 Answer Relevancy가 낮게 나옵니다. 그래서 이 지표는 상태별로 나눠 봐야 합니다.

7. 읽는 법

- **방식 차이가 구성 차이보다 큽니다.** naive → hybrid → hybrid + rerank로 갈수록 네 지표가 모두 오릅니다(192문항 Context Precision 0.857 → 약 0.90, Context Recall 0.657 → 약 0.71). 리랭커가 쓸모 있는 문맥을 위로 올리고 필요한 내용을 더 많이 담습니다.
- **같은 방식 안에서 A와 B의 차이는 대부분 0.01~0.03으로 우연 범위입니다.** naive는 A와 B가 같은 문서를 찾는데도 Faithfulness가 0.783 대 0.806로 달랐습니다. 그만큼 LLM 답변 생성과 채점 자체가 흔들립니다.
- **advanced가 가장 낮습니다.** Context Recall이 0.5 안팎이라 정답에 필요한 내용의 절반쯤만 문맥에 들어갑니다. Answer Relevancy도 0.53~0.57로, 되묻기·보류가 많았습니다. 검색과 답변 모두 개선 여지가 가장 큰 난이도입니다.
- Faithfulness는 basic·intermediate에서 0.83~0.90으로, 답변이 대체로 문맥에 근거합니다. 정답 여부(사실·조건)는 RAGAS가 아니라 Judge 4항목으로 봅니다.

> **참고** A · Qdrant는 이 실험 이후 후보 500, 가중치 0.5 : 0.5로 바꿨습니다(advanced hybrid + rerank 검색 Hit@5 0.828 → 0.879). 이 보고서의 RAGAS는 실험 당시 설정(후보 100, 0.7 : 0.3)으로 만든 답변 기준입니다.