# retrieval_a / retrieval_b 비교 평가

난이도 advanced · 분할 additional, development · 수집 2026-11-12T11:49:55

## 1. 무엇을 비교했나

| 구성 | dense | sparse | 점수 합치기 | 리랭커 |
|---|---|---|---|---|
| **A · 기존** | bge-m3 | bge-m3 sparse. 청크를 모두 받아 직접 계산 | 전체 청크 min-max 가중합 0.7 / 0.3 | bge-reranker-v2-m3, 후보 50 |
| **A · Qdrant** | bge-m3 | bge-m3 sparse. Qdrant m3 벡터로 후보 100개 | 후보 안 min-max 가중합 0.7 / 0.3 | bge-reranker-v2-m3, 후보 50 |
| **B** | bge-m3 | BM25 (Kiwi) | RRF (k=60), 각 30개 후보 | bge-reranker-v2-m3, 후보 50 |

모든 구성이 같은 질문, 같은 답변 프롬프트와 생성 모델(gpt-6-luna, reasoning low), 같은 최종 문맥 수(k=5), 같은 채점기(Langfuse 서버 evaluator)를 씁니다. naive는 sparse를 쓰지 않아 A · 기존과 A · Qdrant가 같으므로 한 번만 실행해 두 구성에 함께 표시했습니다(※).

## 2. 지표 읽는 법

| 묶음 | 지표 | 뜻 | 범위 |
|---|---|---|---|
| **검색** | Hit@5 / Recall@5 / MRR@5 | 참고 근거 문서(evidence_groups의 book_id)를 상위 5개 문맥에서 찾았나 · 몇 개 찾았나 · 몇 위에 처음 나왔나 (문서 단위, 발제 기준) | 0~1 |
| **답변 Judge** | 사실 / 조건 / 근거 / 판단 | 평가 LLM이 참고 정답·채점 기준과 비교해 항목별 충족(1) 또는 미충족(0). 평균 = 충족률 | 0~1 |
| **답변 LLM** | Faithfulness 등 4개 | 서버 evaluator가 RAGAS 방식을 LLM 프롬프트로 채점 (ragas 라이브러리 아님) | 0~1 |
| **운영** | 응답 시간 / 오류 / 토큰 | 질문부터 답변까지 시간(정상 요청 평균), 시스템 오류 수, 답변 생성 입력·출력 토큰 | |

평균은 채점된 문항만으로 계산하고, 해당 없음·평가 불가는 따로 셉니다. 난이도별 문항 수가 n일 때 **3문항(3/n) 미만 차이는 우연일 수 있습니다**(예: 60문항이면 0.05). 같은 문서를 찾은 구성끼리도 답변 점수가 이 정도 흔들렸습니다.

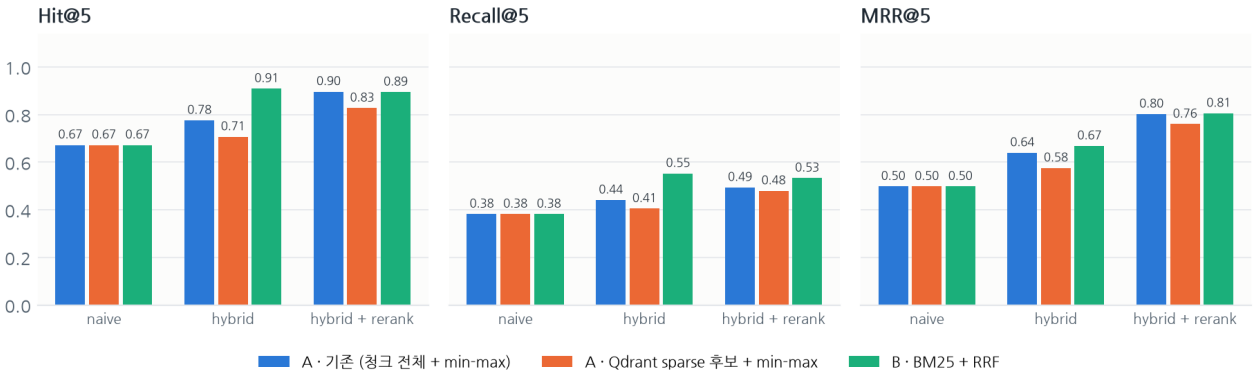
## 3. advanced (60문항)

| 구성 · 방식 | Hit@5 | Recall@5 | MRR@5 | 사실 | 조건 | 근거 | 판단 | Faithful. | 응답(초) | 오류 |
|---|---|---|---|---|---|---|---|---|---|---|
| A-기존 · naive ※ | 0.672 | 0.382 | 0.498 | 0.22 | 0.25 | 0.63 | 0.25 | - | 5.5 | 0 |
| A-기존 · hybrid | 0.776 | 0.441 | 0.640 | 0.22 | 0.30 | 0.50 | 0.23 | - | 23.3 | 0 |
| A-기존 · hybrid + rerank | 0.897 | 0.494 | 0.802 | 0.22 | 0.33 | 0.53 | 0.30 | - | 5.8 | 0 |
| A-Qdrant · naive | 0.672 | 0.382 | 0.498 | 0.22 | 0.25 | 0.63 | 0.25 | - | 5.5 | 0 |
| A-Qdrant · hybrid | 0.707 | 0.405 | 0.576 | 0.17 | 0.23 | 0.55 | 0.22 | - | 4.8 | 0 |
| A-Qdrant · hybrid + rerank | 0.828 | 0.480 | 0.760 | 0.20 | 0.37 | 0.58 | 0.28 | - | 5.1 | 0 |
| B · naive | 0.672 | 0.382 | 0.498 | 0.18 | 0.25 | 0.57 | 0.23 | - | 5.7 | 0 |
| B · hybrid | 0.909 | 0.553 | 0.668 | 0.20 | 0.23 | 0.55 | 0.27 | - | 25.8 | 3 |
| B · hybrid + rerank | 0.895 | 0.534 | 0.806 | 0.23 | 0.32 | 0.52 | 0.32 | - | 5.9 | 1 |

### 핵심 결과

- **검색(Hit·Recall·MRR)**: 평균이 가장 높은 구성은 **B · hybrid + rerank** (0.745). 2위와 차이 0.014로 우연 범위(0.05) 안이라 확실한 1위라고 보기 어렵습니다.
- **답변 Judge 4항목**: 평균이 가장 높은 구성은 **A-Qdrant · hybrid + rerank** (0.358). 2위와 차이 0.013로 우연 범위(0.05) 안이라 확실한 1위라고 보기 어렵습니다.
- **A · 기존 vs A · Qdrant**: 14개 지표 중 우연 범위(0.05) 이상 차이 **7개** (hybrid Hit@5, hybrid MRR@5, hybrid 사실, hybrid 조건, hybrid 근거, hybrid + rerank Hit@5, hybrid + rerank 근거).
- **운영**: 가장 빠른 A-Qdrant · hybrid 4.8초, 가장 느린 B · hybrid 25.8초. 시스템 오류 4건.

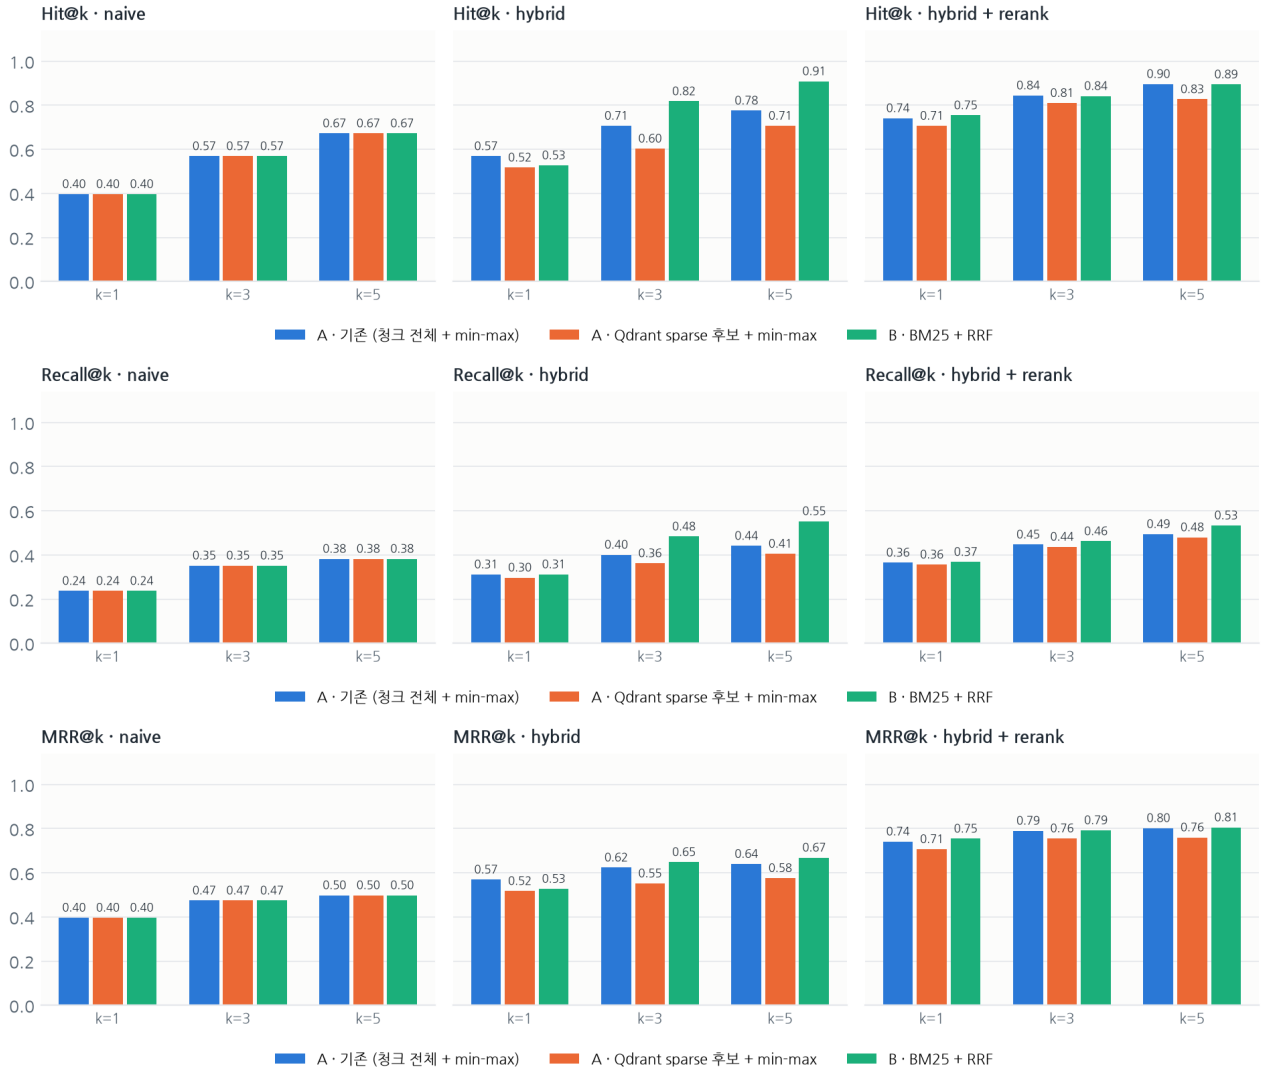
### 검색 성능 (k=5)



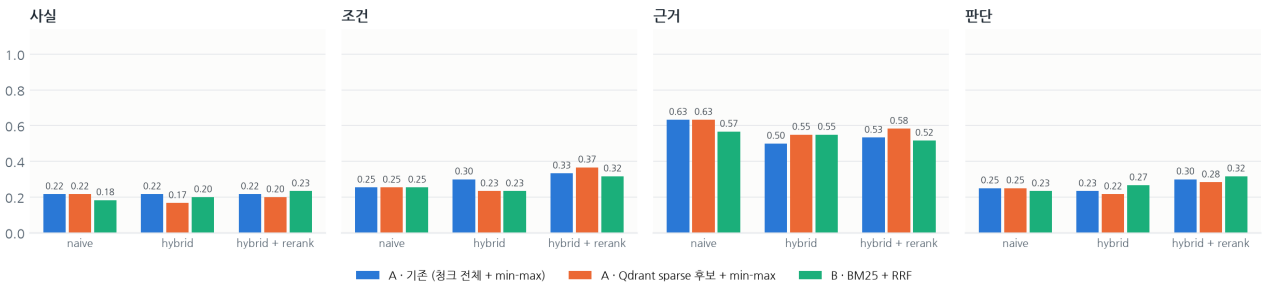
## 검색 지표 전체 (k = 1, 3, 5)

| 구성 · 방식 | Hit@1 | Hit@3 | Hit@5 | Recall@1 | Recall@3 | Recall@5 | MRR@1 | MRR@3 | MRR@5 | 채점 / 제외 |
|---|---|---|---|---|---|---|---|---|---|---|
| A-기존 · naive ※ | 0.397 | 0.569 | 0.672 | 0.237 | 0.352 | 0.382 | 0.397 | 0.474 | 0.498 | 58 / 2 |
| A-기존 · hybrid | 0.569 | 0.707 | 0.776 | 0.312 | 0.401 | 0.441 | 0.569 | 0.624 | 0.640 | 58 / 2 |
| A-기존 · hybrid + rerank | 0.741 | 0.845 | 0.897 | 0.365 | 0.447 | 0.494 | 0.741 | 0.790 | 0.802 | 58 / 2 |
| A-Qdrant · naive | 0.397 | 0.569 | 0.672 | 0.237 | 0.352 | 0.382 | 0.397 | 0.474 | 0.498 | 58 / 2 |
| A-Qdrant · hybrid | 0.517 | 0.603 | 0.707 | 0.297 | 0.362 | 0.405 | 0.517 | 0.552 | 0.576 | 58 / 2 |
| A-Qdrant · hybrid + rerank | 0.707 | 0.810 | 0.828 | 0.356 | 0.437 | 0.480 | 0.707 | 0.756 | 0.760 | 58 / 2 |
| B · naive | 0.397 | 0.569 | 0.672 | 0.237 | 0.352 | 0.382 | 0.397 | 0.474 | 0.498 | 58 / 2 |
| B · hybrid | 0.527 | 0.818 | 0.909 | 0.312 | 0.483 | 0.553 | 0.527 | 0.648 | 0.668 | 55 / 5 |
| B · hybrid + rerank | 0.754 | 0.842 | 0.895 | 0.368 | 0.462 | 0.534 | 0.754 | 0.792 | 0.806 | 57 / 3 |

최종 문맥(모델에 들어간 순서)의 상위 k개로 계산했습니다. Hit@k = 참고 문서를 하나라도 찾은 문항 비율, Recall@k = 찾은 참고 문서 수 / 전체 참고 문서 수, MRR@k = 참고 문서가 처음 나온 순위의 역수 평균. '제외'는 근거 문서가 없는 문항(해당 없음)과 서비스 오류 문항 수입니다.



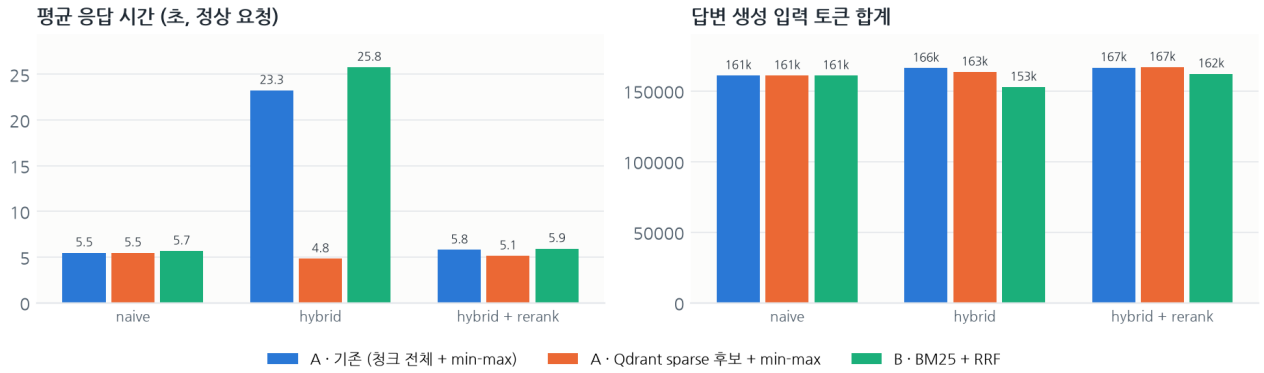
## 답변 품질 · Judge 4항목 (충족률)




## 답변 품질 · LLM 4지표 (서버 evaluator)

서버 evaluator의 LLM 4지표(llm_faithfulness 등)가 이 실험 문항들에 아직 점수를 붙이지 않았습니다. Judge 4항목은 정상적으로 채점되었습니다. 평가기 설정 확인이 필요합니다.

## 운영 지표



## A · 기존 vs A · Qdrant 직접 비교

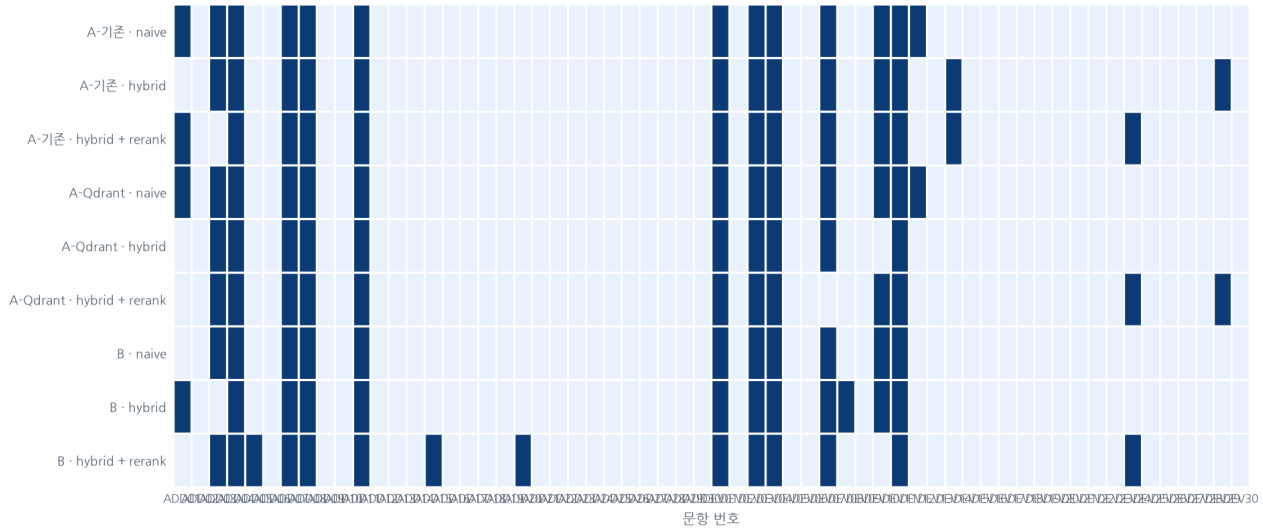
| 방식 | 지표 | A · 기존 | A · Qdrant | 차이 (Q - 기존) | 판정 |
|---|---|---|---|---|---|
| hybrid | Hit@5 | 0.776 | 0.707 | -0.069 | 차이 있음 |
| hybrid | Recall@5 | 0.441 | 0.405 | -0.036 | 우연 범위 |
| hybrid | MRR@5 | 0.640 | 0.576 | -0.064 | 차이 있음 |
| hybrid | 사실 | 0.217 | 0.167 | -0.050 | 차이 있음 |
| hybrid | 조건 | 0.300 | 0.233 | -0.067 | 차이 있음 |
| hybrid | 근거 | 0.500 | 0.550 | +0.050 | 차이 있음 |
| hybrid | 판단 | 0.233 | 0.217 | -0.017 | 우연 범위 |
| hybrid + rerank | Hit@5 | 0.897 | 0.828 | -0.069 | 차이 있음 |
| hybrid + rerank | Recall@5 | 0.494 | 0.480 | -0.014 | 우연 범위 |
| hybrid + rerank | MRR@5 | 0.802 | 0.760 | -0.042 | 우연 범위 |
| hybrid + rerank | 사실 | 0.217 | 0.200 | -0.017 | 우연 범위 |
| hybrid + rerank | 조건 | 0.333 | 0.367 | +0.033 | 우연 범위 |
| hybrid + rerank | 근거 | 0.533 | 0.583 | +0.050 | 차이 있음 |
| hybrid + rerank | 판단 | 0.300 | 0.283 | -0.017 | 우연 범위 |

## 운영 지표 표

| 구성 · 방식 | 요청 | 오류 | 오류율 | 평균 응답(초) | 중앙값(초) | 입력 토큰 | 출력 토큰 | 생성 비용($) |
|---|---|---|---|---|---|---|---|---|
| A-기존 · naive ※ | 60 | 0 | 0% | 5.5 | 4.2 | 160,917 | 14,489 | 0.015 |
| A-기존 · hybrid | 60 | 0 | 0% | 23.3 | 4.4 | 166,224 | 14,172 | 0.014 |
| A-기존 · hybrid + rerank | 60 | 0 | 0% | 5.8 | 5.1 | 166,554 | 13,952 | 0.014 |
| A-Qdrant · naive | 60 | 0 | 0% | 5.5 | 4.2 | 160,917 | 14,489 | 0.015 |
| A-Qdrant · hybrid | 60 | 0 | 0% | 4.8 | 4.4 | 163,466 | 15,022 | 0.015 |
| A-Qdrant · hybrid + rerank | 60 | 0 | 0% | 5.1 | 4.8 | 166,841 | 13,858 | 0.015 |
| B · naive | 60 | 0 | 0% | 5.7 | 4.1 | 160,917 | 14,491 | 0.011 |
| B · hybrid | 60 | 3 | 5% | 25.8 | 5.3 | 152,781 | 14,013 | 0.015 |
| B · hybrid + rerank | 60 | 1 | 2% | 5.9 | 5.1 | 162,155 | 13,701 | 0.014 |

응답 시간은 평가 스크립트가 잰 질문 → 답변 시간(검색 + 리랭킹 + 생성)이고, 생성 비용은 Langfuse 가격표로 계산한 답변 생성 비용입니다. 서버 evaluator 채점 비용은 포함하지 않습니다. A · 기존은 실행마다 첫 요청에서 청크를 모두 받아 오는 시간(advanced 약 7분)이 앞쪽 문항들의 응답 시간에 섞여 평균이 크게 나올 수 있어, 중앙값을 함께 봅니다.

## 문항별 사실(judge_facts) 지도




진한 파랑 = 충족(1), 연한 색 = 미충족(0), 빗금 = 해당 없음 또는 점수 없음. 열 전체가 연한 문항은 어떤 구성도 못 맞힌 문항이라 검색 방식보다 청킹·프롬프트·정답 해석 쪽을 봐야 합니다.

모든 구성이 사실 0점인 문항 (40개): AS-ADD02, AS-ADD06, AS-ADD09, AS-ADD10, AS-ADD12, AS-ADD13, AS-ADD14, AS-ADD16, AS-ADD17, AS-ADD18, AS-ADD19, AS-ADD21, AS-ADD22, AS-ADD23, AS-ADD24, AS-ADD25, AS-ADD26,

AS-ADD27, AS-ADD28, AS-ADD29, AS-ADD30, AS-DEV02, AS-DEV05, AS-DEV06, AS-DEV09, AS-DEV13, AS-DEV15,AS-DEV16, AS-DEV17, AS-DEV18, AS-DEV19, AS-DEV20, AS-DEV21, AS-DEV22, AS-DEV23, AS-DEV25, AS-DEV26,AS-DEV27, AS-DEV28, AS-DEV30

## 4. 한계

- 질문은 공개된 골든 데이터셋(development·additional·expansion_validation)이라 비공개 테스트 성능으로 볼 수 없습니다.
- 답변 점수는 LLM 채점이라 같은 답변도 실행마다 조금씩 달라질 수 있습니다. 대표 사례는 원문과 대조해야 합니다.
- 검색 지표는 문서 단위입니다. 같은 문서의 다른 쪽을 찾아도 맞은 것으로 셉니다.
- A · 기존과 A · Qdrant의 hybrid는 정규화 범위(전체 vs 후보)가 달라 순위가 조금 다를 수 있습니다.
- 서버 evaluator의 LLM 4지표는 ragas 라이브러리가 아니라 LLM 프롬프트 방식입니다. 발제의 RAGAS 공식 기준 점수가 필요하면 langfuse_experiment.py --code-answer-scores로 따로 계산합니다.