retrieval_a / retrieval_b 비교 평가

난이도 advanced · 분할 additional, development · 수집 2026-11-12T15:42:32

1. 무엇을 비교했나

구성	dense	sparse	점수 합치기	리랭커
A · 기존	bge-m3	bge-m3 sparse. 청크를 모두 받아 직접 계산	전체 청크 min-max 가중합 0.7 / 0.3	bge-reranker-v2-m3, 후보 50
A · Qdrant	bge-m3	bge-m3 sparse. Qdrant m3 벡터로 후보 100개	후보 안 min-max 가중합 0.7 / 0.3	bge-reranker-v2-m3, 후보 50
B	bge-m3	BM25 (Kiwi)	RRF (k=60), 각 30개 후보	bge-reranker-v2-m3, 후보 50

모든 구성이 같은 질문, 같은 답변 프롬프트와 생성 모델(gpt-6-luna, reasoning low), 같은 최종 문맥 수(k=5), 같은 채점기(Langfuse 서버 evaluator)를 씁니다. naive는 sparse를 쓰지 않아 A · 기존과 A · Qdrant가 같으므로 한 번만 실행해 두 구성에 함께 표시했습니다(※).

A · Qdrant 설정 변경 (실험 이후)	이 보고서의 실험	현재 hybrid.yaml	advanced hybrid + rerank Hit@5 / Recall@5 / MRR@5 (검색 지표만)
후보 수 candidate_k	100	500	0.828 / 0.480 / 0.760 → 0.879 / 0.494 / 0.811
가중치 dense : sparse	0.7 : 0.3	0.5 : 0.5	basic · intermediate는 같거나 조금 좋아짐

이 보고서의 답변 점수(Judge·RAGAS)는 실험 당시 설정으로 만든 답변 기준입니다. 현재 설정은 검색 지표로만 확인했습니다.

2. 지표 읽는 법

묶음	지표	뜻	범위
검색	Hit@5 / Recall@5 / MRR@5	참고 근거 문서(evidence_groups의 book_id)를 상위 5개 문맥에서 찾았나 · 몇 개 찾았나 · 몇 위에 처음 나왔나 (문서 단위, 발제 기준)	0~1
답변 Judge	사실 / 조건 / 근거 / 판단	평가 LLM이 참고 정답·채점 기준과 비교해 항목별 충족(1) 또는 미충족(0). 평균 = 충족률	0~1
답변 RAGAS	Faithfulness 등 4개	ragas 라이브러리로 코드에서 계산 (Faithfulness는 RAGAS 공식 예제: 질문·답변·실제 최종 문맥). 채점 모델 gpt-6-luna	0~1
운영	응답 시간 / 오류 / 토큰	질문부터 답변까지 시간(정상 요청 평균), 시스템 오류 수, 답변 생성 입력·출력 토큰	

평균은 채점된 문항만으로 계산하고, 해당 없음·평가 불가는 따로 셉니다. 난이도별 문항 수가 n일 때 **3문항(3/n) 미만 차이는 우연일 수 있습니다**(예: 60문항이면 0.05). 같은 문서를 찾은 구성끼리도 답변 점수가 이 정도 흔들렸습니다.

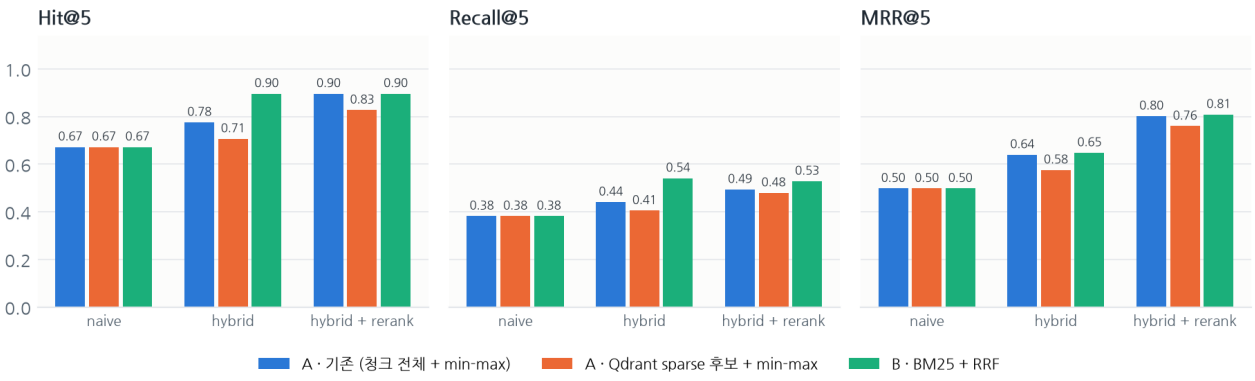
3. advanced (60문항)

구성 · 방식	Hit@5	Recall@5	MRR@5	사실	조건	근거	판단	Faithful.	응답(초)	오류
A-기존 · naive ※	0.672	0.382	0.498	0.22	0.25	0.63	0.25	0.67	5.5	0
A-기존 · hybrid	0.776	0.441	0.640	0.22	0.30	0.50	0.23	0.78	23.3	0
A-기존 · hybrid + rerank	0.897	0.494	0.802	0.22	0.33	0.53	0.30	0.77	5.8	0
A-Qdrant · naive	0.672	0.382	0.498	0.22	0.25	0.63	0.25	0.67	5.5	0
A-Qdrant · hybrid	0.707	0.405	0.576	0.17	0.23	0.55	0.22	0.75	4.8	0
A-Qdrant · hybrid + rerank	0.828	0.480	0.760	0.20	0.37	0.58	0.28	0.77	5.1	0
B · naive	0.672	0.382	0.498	0.15	0.30	0.58	0.25	0.73	5.0	0
B · hybrid	0.897	0.542	0.648	0.20	0.30	0.53	0.25	0.73	12.7	0
B · hybrid + rerank	0.897	0.529	0.809	0.23	0.37	0.53	0.32	0.75	8.8	0

핵심 결과

- **검색(Hit·Recall·MRR)**: 평균이 가장 높은 구성은 **B · hybrid + rerank** (0.745). 2위와 차이 0.014로 우연 범위(0.05) 안이라 확실한 1위라고 보기 어렵습니다.
- **답변 Judge 4항목**: 평균이 가장 높은 구성은 **B · hybrid + rerank** (0.362). 2위와 차이 0.004로 우연 범위(0.05) 안이라 확실한 1위라고 보기 어렵습니다.
- **답변 RAGAS 4지표**: 평균이 가장 높은 구성은 **B · hybrid + rerank** (0.674). 2위와 차이 0.013로 우연 범위(0.05) 안이라 확실한 1위라고 보기 어렵습니다.
- **A · 기존 vs A · Qdrant**: 22개 지표 중 우연 범위(0.05) 이상 차이 **9개** (hybrid Hit@5, hybrid MRR@5, hybrid 사실, hybrid 조건, hybrid 근거, hybrid Context Precision, hybrid Context Recall, hybrid + rerank Hit@5, hybrid + rerank 근거).
- **운영**: 가장 빠른 A-Qdrant · hybrid 4.8초, 가장 느린 A-기존 · hybrid 23.3초. 시스템 오류 0건.

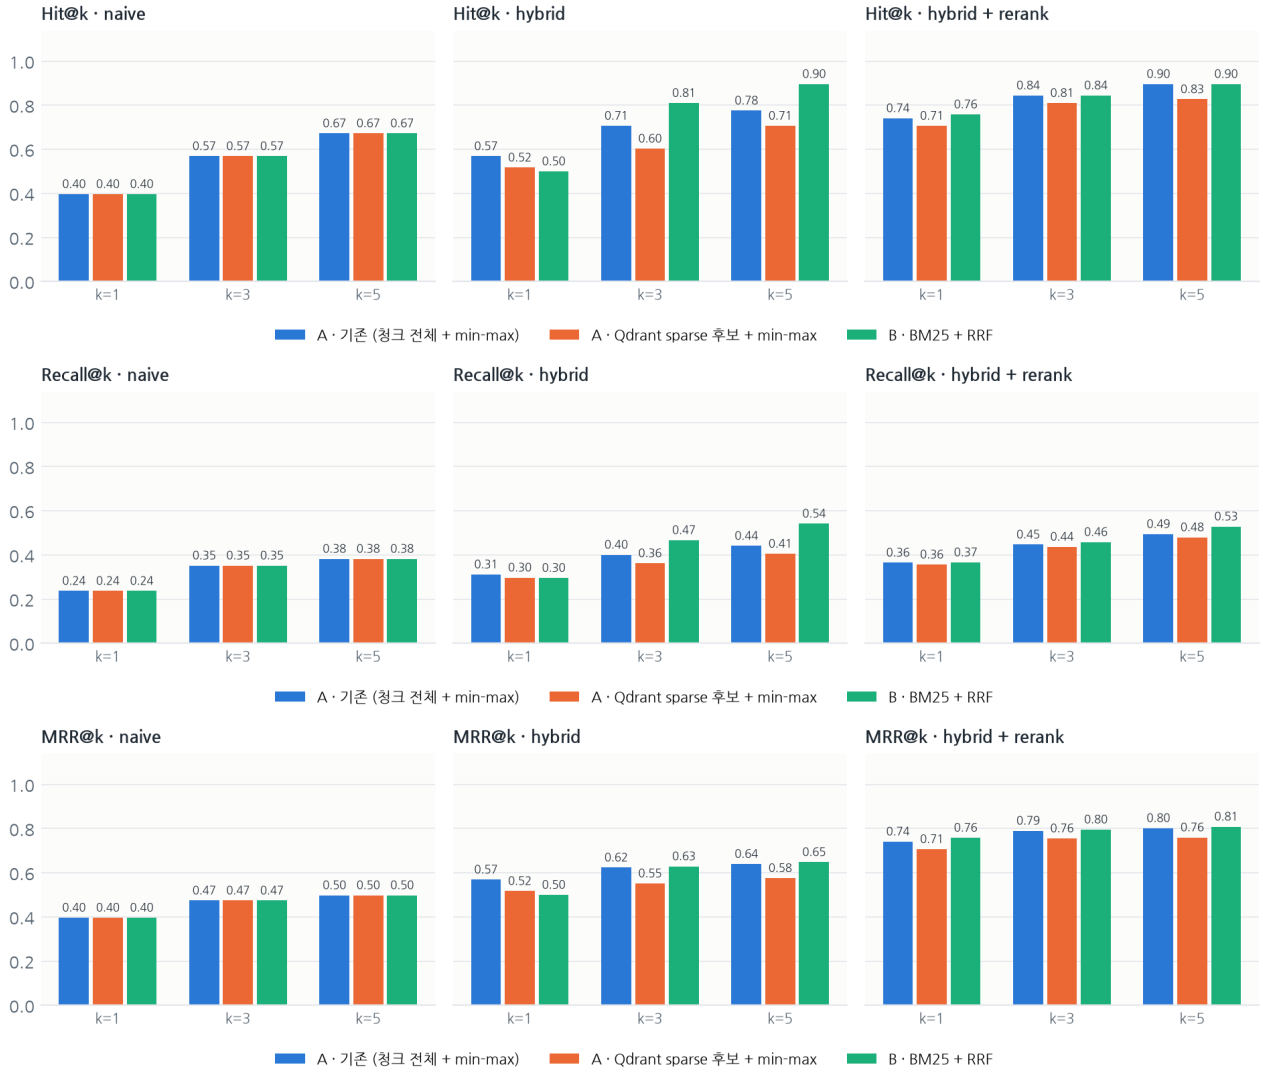
검색 성능 (k=5)



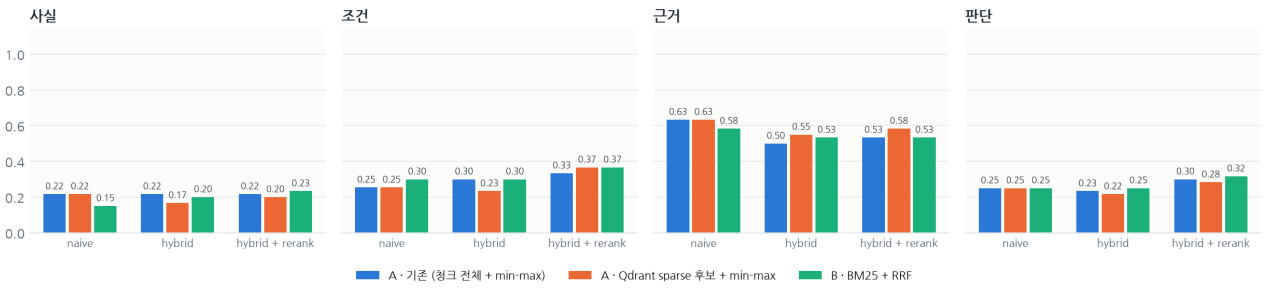
검색 지표 전체 (k = 1, 3, 5)

구성 · 방식	Hit@1	Hit@3	Hit@5	Recall@1	Recall@3	Recall@5	MRR@1	MRR@3	MRR@5	채점 / 제외
A-기존 · naive ※	0.397	0.569	0.672	0.237	0.352	0.382	0.397	0.474	0.498	58 / 2
A-기존 · hybrid	0.569	0.707	0.776	0.312	0.401	0.441	0.569	0.624	0.640	58 / 2
A-기존 · hybrid + rerank	0.741	0.845	0.897	0.365	0.447	0.494	0.741	0.790	0.802	58 / 2
A-Qdrant · naive	0.397	0.569	0.672	0.237	0.352	0.382	0.397	0.474	0.498	58 / 2
A-Qdrant · hybrid	0.517	0.603	0.707	0.297	0.362	0.405	0.517	0.552	0.576	58 / 2
A-Qdrant · hybrid + rerank	0.707	0.810	0.828	0.356	0.437	0.480	0.707	0.756	0.760	58 / 2
B · naive	0.397	0.569	0.672	0.237	0.352	0.382	0.397	0.474	0.498	58 / 2
B · hybrid	0.500	0.810	0.897	0.296	0.467	0.542	0.500	0.629	0.648	58 / 2
B · hybrid + rerank	0.759	0.845	0.897	0.366	0.458	0.529	0.759	0.796	0.809	58 / 2

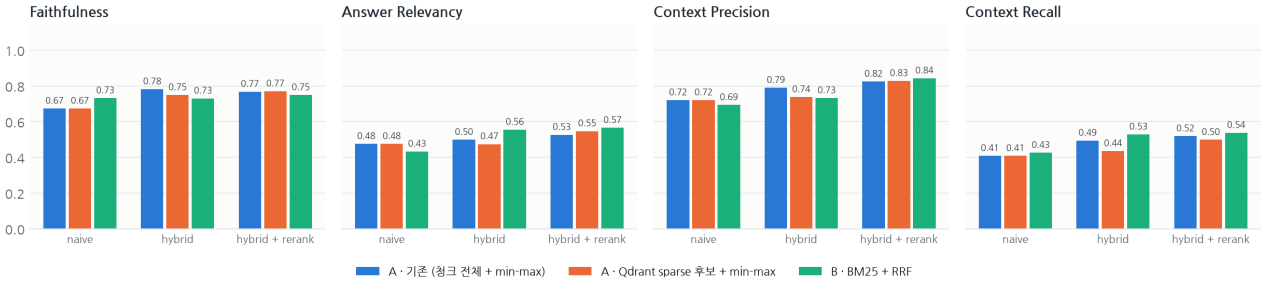
최종 문맥(모델에 들어간 순서)의 상위 k개로 계산했습니다. Hit@k = 참고 문서를 하나라도 찾은 문항 비율, Recall@k = 찾은 참고 문서 수 / 전체 참고 문서 수, MRR@k = 참고 문서가 처음 나온 순위의 역수 평균. '제외'는 근거 문서가 없는 문항(해당 없음)과 서비스 오류 문항 수입니다.



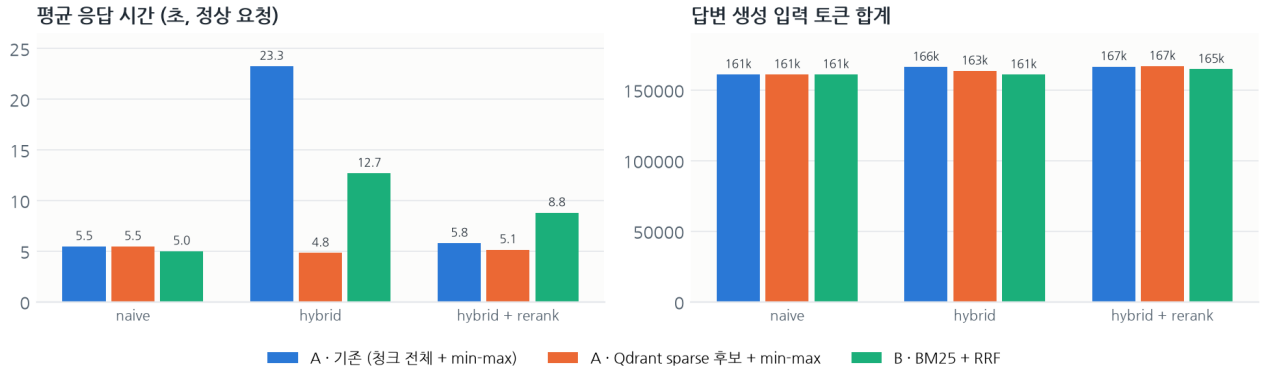
답변 품질 · Judge 4항목 (충족률)



답변 품질 · RAGAS 4지표 (ragas 라이브러리)



운영 지표



A · 기존 vs A · Qdrant 직접 비교

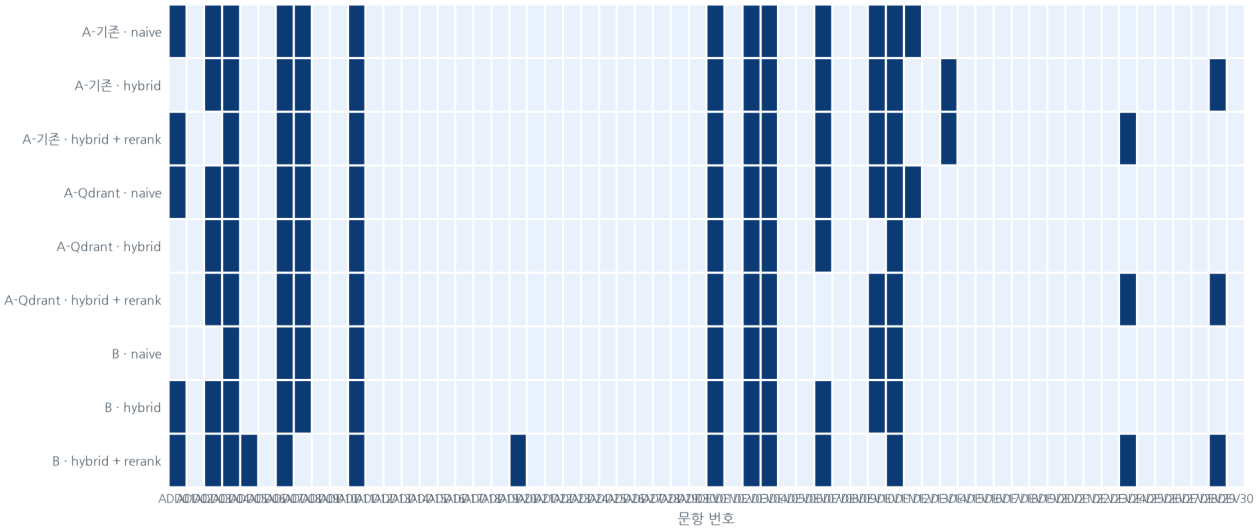
방식	지표	A · 기존	A · Qdrant	차이 (Q - 기존)	판정
hybrid	Hit@5	0.776	0.707	-0.069	차이 있음
hybrid	Recall@5	0.441	0.405	-0.036	우연 범위
hybrid	MRR@5	0.640	0.576	-0.064	차이 있음
hybrid	사실	0.217	0.167	-0.050	차이 있음
hybrid	조건	0.300	0.233	-0.067	차이 있음
hybrid	근거	0.500	0.550	+0.050	차이 있음
hybrid	판단	0.233	0.217	-0.017	우연 범위
hybrid	Faithfulness	0.782	0.749	-0.033	우연 범위
hybrid	Answer Relevancy	0.498	0.475	-0.024	우연 범위
hybrid	Context Precision	0.790	0.738	-0.052	차이 있음
hybrid	Context Recall	0.494	0.435	-0.059	차이 있음
hybrid + rerank	Hit@5	0.897	0.828	-0.069	차이 있음
hybrid + rerank	Recall@5	0.494	0.480	-0.014	우연 범위
hybrid + rerank	MRR@5	0.802	0.760	-0.042	우연 범위
hybrid + rerank	사실	0.217	0.200	-0.017	우연 범위
hybrid + rerank	조건	0.333	0.367	+0.033	우연 범위
hybrid + rerank	근거	0.533	0.583	+0.050	차이 있음
hybrid + rerank	판단	0.300	0.283	-0.017	우연 범위
hybrid + rerank	Faithfulness	0.768	0.770	+0.003	우연 범위
hybrid + rerank	Answer Relevancy	0.527	0.547	+0.020	우연 범위
hybrid + rerank	Context Precision	0.824	0.828	+0.004	우연 범위
hybrid + rerank	Context Recall	0.519	0.498	-0.020	우연 범위

운영 지표 표

구성 · 방식	요청	오류	오류율	평균 응답(초)	중앙값(초)	입력 토큰	출력 토큰	생성 비용($)
A-기존 · naive ※	60	0	0%	5.5	4.2	160,917	14,489	0.015
A-기존 · hybrid	60	0	0%	23.3	4.4	166,224	14,172	0.014
A-기존 · hybrid + rerank	60	0	0%	5.8	5.1	166,554	13,952	0.014
A-Qdrant · naive	60	0	0%	5.5	4.2	160,917	14,489	0.015
A-Qdrant · hybrid	60	0	0%	4.8	4.4	163,466	15,022	0.015
A-Qdrant · hybrid + rerank	60	0	0%	5.1	4.8	166,841	13,858	0.015
B · naive	60	0	0%	5.0	4.9	160,917	14,635	0.015
B · hybrid	60	0	0%	12.7	5.5	160,853	15,175	0.015
B · hybrid + rerank	60	0	0%	8.8	7.2	164,695	13,598	0.015

응답 시간은 평가 스크립트가 잰 질문 → 답변 시간(검색 + 리랭킹 + 생성)이고, 생성 비용은 Langfuse 가격표로 계산한 답변 생성 비용입니다. 서버 evaluator 채점 비용은 포함하지 않습니다. A · 기존은 실행마다 첫 요청에서 청크를 모두 받아 오는 시간(advanced 약 7분)이 앞쪽 문항들의 응답 시간에 섞여 평균이 크게 나올 수 있어, 중앙값을 함께 봅니다.

문항별 사실(judge_facts) 지도



진한 파랑 = 충족(1), 연한 색 = 미충족(0), 빗금 = 해당 없음 또는 점수 없음. 열 전체가 연한 문항은 어떤 구성도 못 맞힌 문항이라 검색 방식보다 청킹·프롬프트·정답 해석 쪽을 봐야 합니다.

모든 구성이 사실 0점인 문항 (42개): AS-ADD02, AS-ADD06, AS-ADD09, AS-ADD10, AS-ADD12, AS-ADD13, AS-ADD14, AS-ADD15, AS-ADD16, AS-ADD17, AS-ADD18, AS-ADD19, AS-ADD21, AS-ADD22, AS-ADD23, AS-ADD24, AS-ADD25, AS-ADD26, AS-ADD27, AS-ADD28, AS-ADD29, AS-ADD30, AS-DEV02, AS-DEV05, AS-DEV06, AS-DEV08, AS-DEV09, AS-DEV13, AS-DEV15, AS-DEV16, AS-DEV17, AS-DEV18, AS-DEV19, AS-DEV20, AS-DEV21, AS-DEV22, AS-DEV23, AS-DEV25, AS-DEV26, AS-DEV27, AS-DEV28, AS-DEV30

4. 한계

- 질문은 공개된 골든 데이터셋(development·additional·expansion_validation)이라 비공개 테스트 성능으로 볼 수 없습니다.
- 답변 점수는 LLM 채점이라 같은 답변도 실행마다 조금씩 달라질 수 있습니다. 대표 사례는 원문과 대조해야 합니다.
- 검색 지표는 문서 단위입니다. 같은 문서의 다른 쪽을 찾아도 맞은 것으로 셉니다.
- A · 기존과 A · Qdrant의 hybrid는 정규화 범위(전체 vs 후보)가 달라 순위가 조금 다를 수 있습니다. A · Qdrant는 실험 이후 후보 500, 가중치 0.5 : 0.5로 바꿨습니다(1절 표).
- RAGAS는 실험 뒤에 저장된 답변·최종 문맥으로 따로 계산해 올렸습니다(답변은 다시 만들지 않음). 같은 팀 채점 코드(quality.py)를 씁니다.
- Judge는 Langfuse 서버 evaluator가 채점합니다. 해당 없음·평가 불가는 이유 첫머리 표시([해당 없음]·[평가 불가])로 읽어 평균에서 뺍니다(server_judge_summary.py 규칙).