retrieval_a / retrieval_b 비교 평가

난이도 basic · 분할 additional, development, expansion_validation · 수집 2026-11-12T11:49:55

1. 무엇을 비교했나

구성	dense	sparse	점수 합치기	리랭커
A · 기존	bge-m3	bge-m3 sparse. 청크를 모두 받아 직접 계산	전체 청크 min-max 가중합 0.7 / 0.3	bge-reranker-v2-m3, 후보 50
A · Qdrant	bge-m3	bge-m3 sparse. Qdrant m3 벡터로 후보 100개	후보 안 min-max 가중합 0.7 / 0.3	bge-reranker-v2-m3, 후보 50
B	bge-m3	BM25 (Kiwi)	RRF (k=60), 각 30개 후보	bge-reranker-v2-m3, 후보 50

모든 구성이 같은 질문, 같은 답변 프롬프트와 생성 모델(gpt-6-luna, reasoning low), 같은 최종 문맥 수(k=5), 같은 채점기(Langfuse 서버 evaluator)를 씁니다. naive는 sparse를 쓰지 않아 A · 기존과 A · Qdrant가 같으므로 한 번만 실행해 두 구성에 함께 표시했습니다(※).

2. 지표 읽는 법

묶음	지표	뜻	범위
검색	Hit@5 / Recall@5 / MRR@5	참고 근거 문서(evidence_groups의 book_id)를 상위 5개 문맥에서 찾았나 · 몇 개 찾았나 · 몇 위에 처음 나왔나 (문서 단위, 발제 기준)	0~1
답변 Judge	사실 / 조건 / 근거 / 판단	평가 LLM이 참고 정답·채점 기준과 비교해 항목별 충족(1) 또는 미충족(0). 평균 = 충족률	0~1
답변 LLM	Faithfulness 등 4개	서버 evaluator가 RAGAS 방식을 LLM 프롬프트로 채점 (ragas 라이브러리 아님)	0~1
운영	응답 시간 / 오류 / 토큰	질문부터 답변까지 시간(정상 요청 평균), 시스템 오류 수, 답변 생성 입력·출력 토큰	

평균은 채점된 문항만으로 계산하고, 해당 없음·평가 불가는 따로 셉니다. 난이도별 문항 수가 n일 때 **3문항(3/n) 미만 차이는 우연일 수 있습니다**(예: 60문항이면 0.05). 같은 문서를 찾은 구성끼리도 답변 점수가 이 정도 흔들렸습니다.

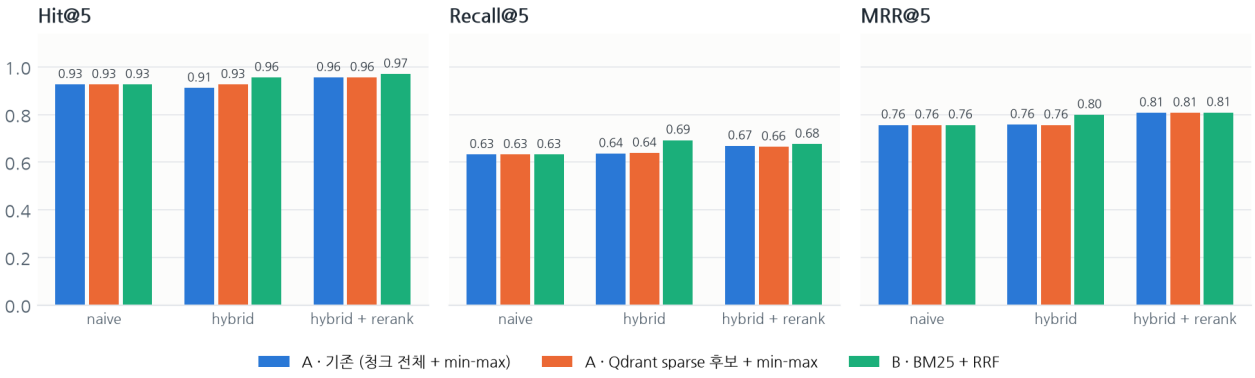
3. basic (72문항)

구성 · 방식	Hit@5	Recall@5	MRR@5	사실	조건	근거	판단	Faithful.	응답(초)	오류
A-기존 · naive ※	0.926	0.632	0.757	0.62	0.79	0.81	0.67	-	5.4	0
A-기존 · hybrid	0.912	0.636	0.758	0.64	0.86	0.82	0.71	-	5.1	0
A-기존 · hybrid + rerank	0.956	0.669	0.808	0.71	0.82	0.81	0.76	-	4.8	0
A-Qdrant · naive	0.926	0.632	0.757	0.62	0.79	0.81	0.67	-	5.4	0
A-Qdrant · hybrid	0.926	0.639	0.757	0.65	0.86	0.81	0.68	-	4.4	0
A-Qdrant · hybrid + rerank	0.956	0.665	0.808	0.68	0.86	0.83	0.69	-	4.4	0
B · naive	0.926	0.632	0.757	0.61	0.78	0.76	0.65	-	5.4	0
B · hybrid	0.956	0.693	0.800	0.57	0.72	0.75	0.65	-	4.3	0
B · hybrid + rerank	0.971	0.676	0.809	0.65	0.76	0.81	0.78	-	4.4	0

핵심 결과

- **검색(Hit·Recall·MRR)**: 평균이 가장 높은 구성은 **B · hybrid + rerank** (0.819). 2위와 차이 0.003로 우연 범위(0.04) 안이라 확실한 1위라고 보기 어렵습니다.
- **답변 Judge 4항목**: 평균이 가장 높은 구성은 **A-기존 · hybrid + rerank** (0.774). 2위와 차이 0.007로 우연 범위(0.04) 안이라 확실한 1위라고 보기 어렵습니다.
- **A · 기존 vs A · Qdrant**: 14개 지표 중 우연 범위(0.04) 이상 차이 **1개** (hybrid + rerank 판단).
- **운영**: 가장 빠른 B · hybrid 4.3초, 가장 느린 A-기존 · naive 5.4초. 시스템 오류 0건.

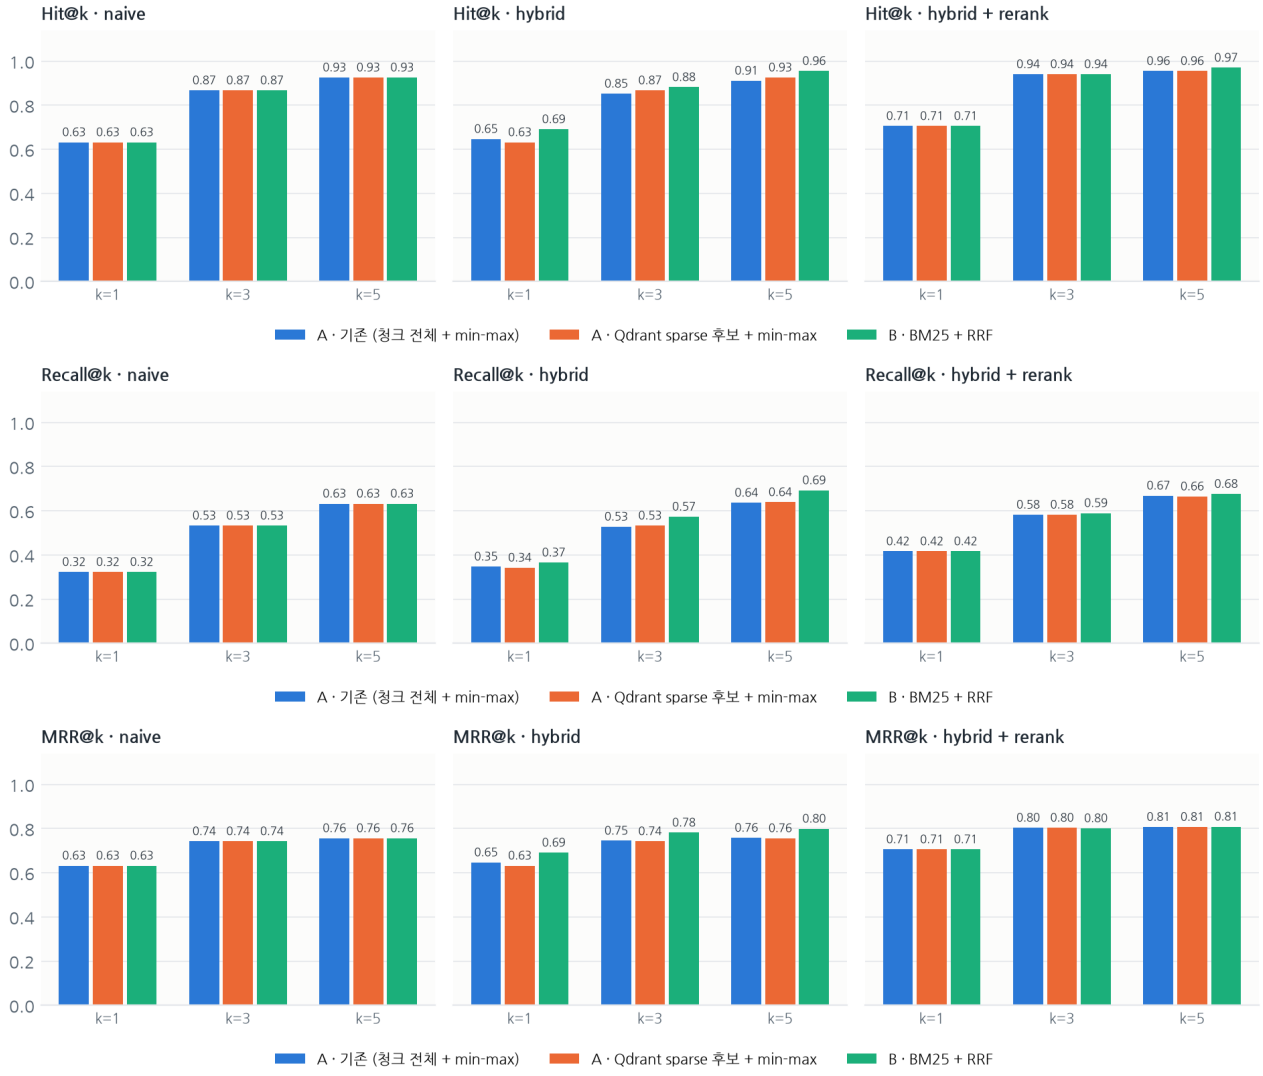
검색 성능 (k=5)



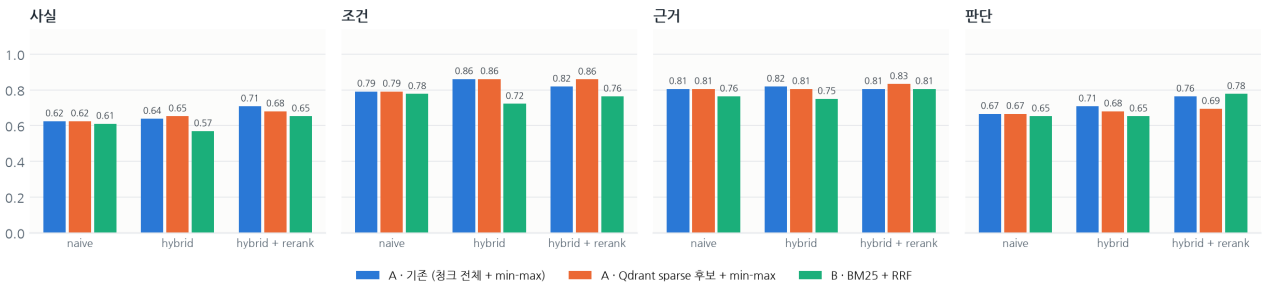
검색 지표 전체 (k = 1, 3, 5)

구성 · 방식	Hit@1	Hit@3	Hit@5	Recall@1	Recall@3	Recall@5	MRR@1	MRR@3	MRR@5	채점 / 제외
A-기존 · naive ※	0.632	0.868	0.926	0.323	0.533	0.632	0.632	0.743	0.757	68 / 4
A-기존 · hybrid	0.647	0.853	0.912	0.347	0.528	0.636	0.647	0.745	0.758	68 / 4
A-기존 · hybrid + rerank	0.706	0.941	0.956	0.416	0.582	0.669	0.706	0.804	0.808	68 / 4
A-Qdrant · naive	0.632	0.868	0.926	0.323	0.533	0.632	0.632	0.743	0.757	68 / 4
A-Qdrant · hybrid	0.632	0.868	0.926	0.342	0.533	0.639	0.632	0.743	0.757	68 / 4
A-Qdrant · hybrid + rerank	0.706	0.941	0.956	0.416	0.582	0.665	0.706	0.804	0.808	68 / 4
B · naive	0.632	0.868	0.926	0.323	0.533	0.632	0.632	0.743	0.757	68 / 4
B · hybrid	0.691	0.882	0.956	0.366	0.573	0.693	0.691	0.782	0.800	68 / 4
B · hybrid + rerank	0.706	0.941	0.971	0.416	0.590	0.676	0.706	0.801	0.809	68 / 4

최종 문맥(모델에 들어간 순서)의 상위 k개로 계산했습니다. Hit@k = 참고 문서를 하나라도 찾은 문항 비율, Recall@k = 찾은 참고 문서 수 / 전체 참고 문서 수, MRR@k = 참고 문서가 처음 나온 순위의 역수 평균. '제외'는 근거 문서가 없는 문항(해당 없음)과 서비스 오류 문항 수입니다.



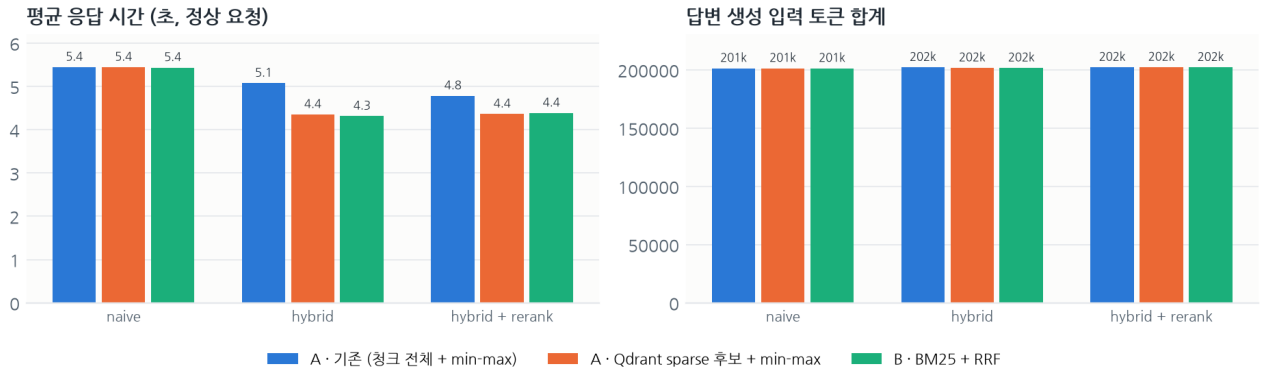
답변 품질 · Judge 4항목 (충족률)



답변 품질 · LLM 4지표 (서버 evaluator)

서버 evaluator의 LLM 4지표(llm_faithfulness 등)가 이 실험 문항들에 아직 점수를 붙이지 않았습니다. Judge 4항목은 정상적으로 채점되었습니다. 평가기 설정 확인이 필요합니다.

운영 지표



A · 기존 vs A · Qdrant 직접 비교

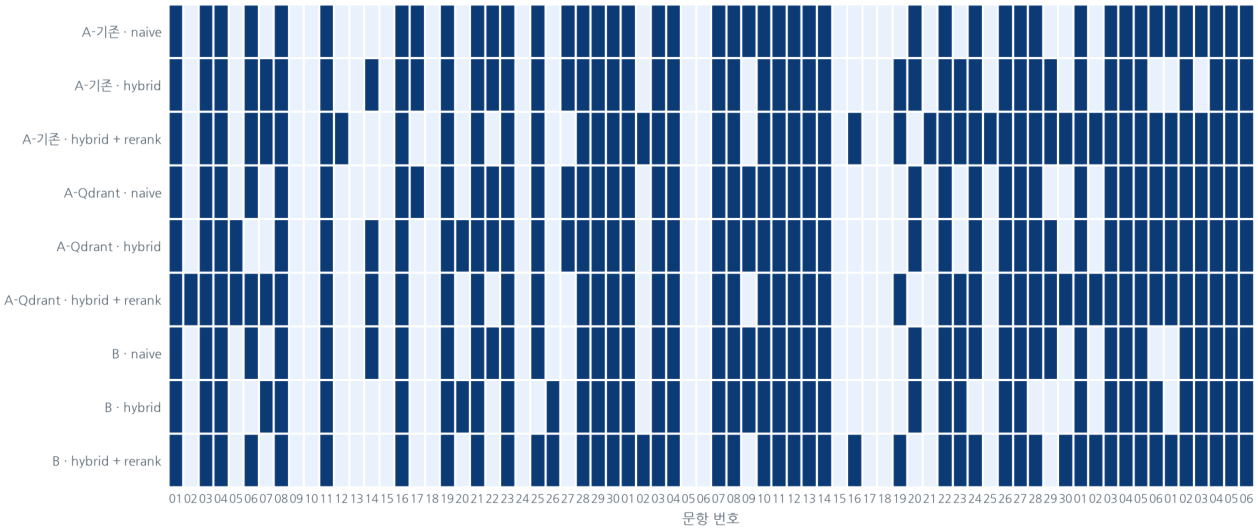
방식	지표	A · 기존	A · Qdrant	차이 (Q - 기존)	판정
hybrid	Hit@5	0.912	0.926	+0.015	우연 범위
hybrid	Recall@5	0.636	0.639	+0.002	우연 범위
hybrid	MRR@5	0.758	0.757	-0.002	우연 범위
hybrid	사실	0.639	0.653	+0.014	우연 범위
hybrid	조건	0.861	0.861	+0.000	우연 범위
hybrid	근거	0.819	0.806	-0.014	우연 범위
hybrid	판단	0.708	0.681	-0.028	우연 범위
hybrid + rerank	Hit@5	0.956	0.956	+0.000	우연 범위
hybrid + rerank	Recall@5	0.669	0.665	-0.004	우연 범위
hybrid + rerank	MRR@5	0.808	0.808	+0.000	우연 범위
hybrid + rerank	사실	0.708	0.681	-0.028	우연 범위
hybrid + rerank	조건	0.819	0.859	+0.040	우연 범위
hybrid + rerank	근거	0.806	0.833	+0.028	우연 범위
hybrid + rerank	판단	0.764	0.694	-0.069	차이 있음

운영 지표 표

구성 · 방식	요청	오류	오류율	평균 응답(초)	중앙값(초)	입력 토큰	출력 토큰	생성 비용($)
A-기존 · naive ※	72	0	0%	5.4	3.3	201,378	16,823	0.017
A-기존 · hybrid	72	0	0%	5.1	3.3	202,168	16,800	0.014
A-기존 · hybrid + rerank	72	0	0%	4.8	3.5	202,234	16,398	0.011
A-Qdrant · naive	72	0	0%	5.4	3.3	201,378	16,823	0.017
A-Qdrant · hybrid	72	0	0%	4.4	3.5	201,770	17,227	0.017
A-Qdrant · hybrid + rerank	72	0	0%	4.4	3.7	202,302	16,259	0.016
B · naive	72	0	0%	5.4	3.6	201,378	16,564	0.011
B · hybrid	72	0	0%	4.3	3.4	201,727	16,540	0.017
B · hybrid + rerank	72	0	0%	4.4	3.8	202,118	16,241	0.012

응답 시간은 평가 스크립트가 잰 질문 → 답변 시간(검색 + 리랭킹 + 생성)이고, 생성 비용은 Langfuse 가격표로 계산한 답변 생성 비용입니다. 서버 evaluator 채점 비용은 포함하지 않습니다. A · 기존은 실행마다 첫 요청에서 청크를 모두 받아 오는 시간(advanced 약 7분)이 앞쪽 문항들의 응답 시간에 섞여 평균이 크게 나올 수 있어, 중앙값을 함께 봅니다.

문항별 사실(judge_facts) 지도



진한 파랑 = 충족(1), 연한 색 = 미충족(0), 빗금 = 해당 없음 또는 점수 없음. 열 전체가 연한 문항은 어떤 구성도 못 맞힌 문항이라 검색 방식보다 청킹·프롬프트·정답 해석 쪽을 봐야 합니다.
모든 구성이 사실 0점인 문항 (11개): S-DEV-09, S-DEV-10, S-DEV-13, S-DEV-15, S-DEV-18, S-DEV-24, S-FINAL-05, S-FINAL-06, S-FINAL-15, S-FINAL-17, S-FINAL-18

4. 한계

- 질문은 공개된 골든 데이터셋(development·additional·expansion_validation)이라 비공개 테스트 성능으로 볼 수 없습니다.
- 답변 점수는 LLM 채점이라 같은 답변도 실행마다 조금씩 달라질 수 있습니다. 대표 사례는 원문과 대조해야 합니다.
- 검색 지표는 문서 단위입니다. 같은 문서의 다른 쪽을 찾아도 맞은 것으로 셉니다.
- A · 기존과 A · Qdrant의 hybrid는 정규화 범위(전체 vs 후보)가 달라 순위가 조금 다를 수 있습니다.
- 서버 evaluator의 LLM 4지표는 ragas 라이브러리가 아니라 LLM 프롬프트 방식입니다. 발제의 RAGAS 공식 기준 점수가 필요하면 langfuse_experiment.py --code-answer-scores로 따로 계산합니다.