# retrieval_a / retrieval_b 비교 평가

난이도 basic · 분할 additional, development, expansion_validation · 수집 2026-11-12T15:42:32

## 1. 무엇을 비교했나

| 구성 | dense | sparse | 점수 합치기 | 리랭커 |
|---|---|---|---|---|
| **A · 기존** | bge-m3 | bge-m3 sparse. 청크를 모두 받아 직접 계산 | 전체 청크 min-max 가중합 0.7 / 0.3 | bge-reranker-v2-m3, 후보 50 |
| **A · Qdrant** | bge-m3 | bge-m3 sparse. Qdrant m3 벡터로 후보 100개 | 후보 안 min-max 가중합 0.7 / 0.3 | bge-reranker-v2-m3, 후보 50 |
| **B** | bge-m3 | BM25 (Kiwi) | RRF (k=60), 각 30개 후보 | bge-reranker-v2-m3, 후보 50 |

모든 구성이 같은 질문, 같은 답변 프롬프트와 생성 모델(gpt-6-luna, reasoning low), 같은 최종 문맥 수(k=5), 같은 채점기(Langfuse 서버 evaluator)를 씁니다. naive는 sparse를 쓰지 않아 A · 기존과 A · Qdrant가 같으므로 한 번만 실행해 두 구성에 함께 표시했습니다(※).

| A · Qdrant 설정 변경 (실험 이후) | 이 보고서의 실험 | 현재 hybrid.yaml | advanced hybrid + rerank Hit@5 / Recall@5 / MRR@5 (검색 지표만) |
|---|---|---|---|
| **후보 수 candidate_k** | 100 | 500 | 0.828 / 0.480 / 0.760 → 0.879 / 0.494 / 0.811 |
| **가중치 dense : sparse** | 0.7 : 0.3 | 0.5 : 0.5 | basic · intermediate는 같거나 조금 좋아짐 |

이 보고서의 답변 점수(Judge·RAGAS)는 실험 당시 설정으로 만든 답변 기준입니다. 현재 설정은 검색 지표로만 확인했습니다.

## 2. 지표 읽는 법

| 묶음 | 지표 | 뜻 | 범위 |
|---|---|---|---|
| **검색** | Hit@5 / Recall@5 / MRR@5 | 참고 근거 문서(evidence_groups의 book_id)를 상위 5개 문맥에서 찾았나 · 몇 개 찾았나 · 몇 위에 처음 나왔나 (문서 단위, 발제 기준) | 0~1 |
| **답변 Judge** | 사실 / 조건 / 근거 / 판단 | 평가 LLM이 참고 정답·채점 기준과 비교해 항목별 충족(1) 또는 미충족(0). 평균 = 충족률 | 0~1 |
| **답변 RAGAS** | Faithfulness 등 4개 | ragas 라이브러리로 코드에서 계산 (Faithfulness는 RAGAS 공식 예제: 질문·답변·실제 최종 문맥). 채점 모델 gpt-6-luna | 0~1 |
| **운영** | 응답 시간 / 오류 / 토큰 | 질문부터 답변까지 시간(정상 요청 평균), 시스템 오류 수, 답변 생성 입력·출력 토큰 | |

평균은 채점된 문항만으로 계산하고, 해당 없음·평가 불가는 따로 셉니다. 난이도별 문항 수가 n일 때 **3문항(3/n) 미만 차이는 우연일 수 있습니다**(예: 60문항이면 0.05). 같은 문서를 찾은 구성끼리도 답변 점수가 이 정도 흔들렸습니다.

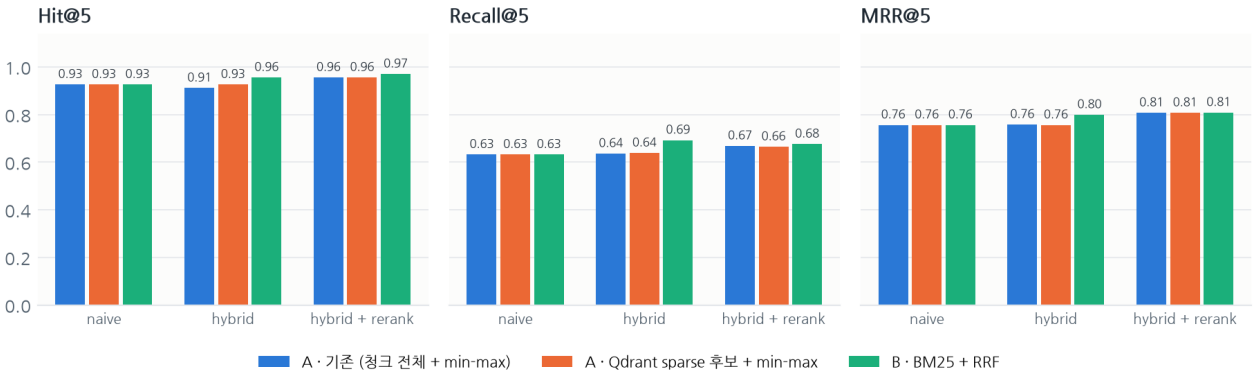
## 3. basic (72문항)

| 구성 · 방식 | Hit@5 | Recall@5 | MRR@5 | 사실 | 조건 | 근거 | 판단 | Faithful. | 응답(초) | 오류 |
|---|---|---|---|---|---|---|---|---|---|---|
| A-기존 · naive ※ | 0.926 | 0.632 | 0.757 | 0.62 | 0.79 | 0.81 | 0.67 | 0.83 | 5.4 | 0 |
| A-기존 · hybrid | 0.912 | 0.636 | 0.758 | 0.64 | 0.86 | 0.82 | 0.71 | 0.86 | 5.1 | 0 |
| A-기존 · hybrid + rerank | 0.956 | 0.669 | 0.808 | 0.71 | 0.82 | 0.81 | 0.76 | 0.87 | 4.8 | 0 |
| A-Qdrant · naive | 0.926 | 0.632 | 0.757 | 0.62 | 0.79 | 0.81 | 0.67 | 0.83 | 5.4 | 0 |
| A-Qdrant · hybrid | 0.926 | 0.639 | 0.757 | 0.65 | 0.86 | 0.81 | 0.68 | 0.88 | 4.4 | 0 |
| A-Qdrant · hybrid + rerank | 0.956 | 0.665 | 0.808 | 0.68 | 0.86 | 0.83 | 0.69 | 0.90 | 4.4 | 0 |
| B · naive | 0.926 | 0.632 | 0.757 | 0.61 | 0.78 | 0.76 | 0.65 | 0.85 | 5.4 | 0 |
| B · hybrid | 0.956 | 0.693 | 0.800 | 0.57 | 0.72 | 0.75 | 0.65 | 0.87 | 4.3 | 0 |
| B · hybrid + rerank | 0.971 | 0.676 | 0.809 | 0.65 | 0.76 | 0.81 | 0.78 | 0.87 | 4.4 | 0 |

### 핵심 결과

- **검색(Hit·Recall·MRR)**: 평균이 가장 높은 구성은 **B · hybrid + rerank** (0.819). 2위와 차이 0.003로 우연 범위(0.04) 안이라 확실한 1위라고 보기 어렵습니다.
- **답변 Judge 4항목**: 평균이 가장 높은 구성은 **A-기존 · hybrid + rerank** (0.774). 2위와 차이 0.007로 우연 범위(0.04) 안이라 확실한 1위라고 보기 어렵습니다.
- **답변 RAGAS 4지표**: 평균이 가장 높은 구성은 **A-Qdrant · hybrid + rerank** (0.868). 2위와 차이 0.012로 우연 범위(0.04) 안이라 확실한 1위라고 보기 어렵습니다.
- **A · 기존 vs A · Qdrant**: 22개 지표 중 우연 범위(0.04) 이상 차이 **1개** (hybrid + rerank 판단).
- **운영**: 가장 빠른 B · hybrid 4.3초, 가장 느린 A-기존 · naive 5.4초. 시스템 오류 0건.

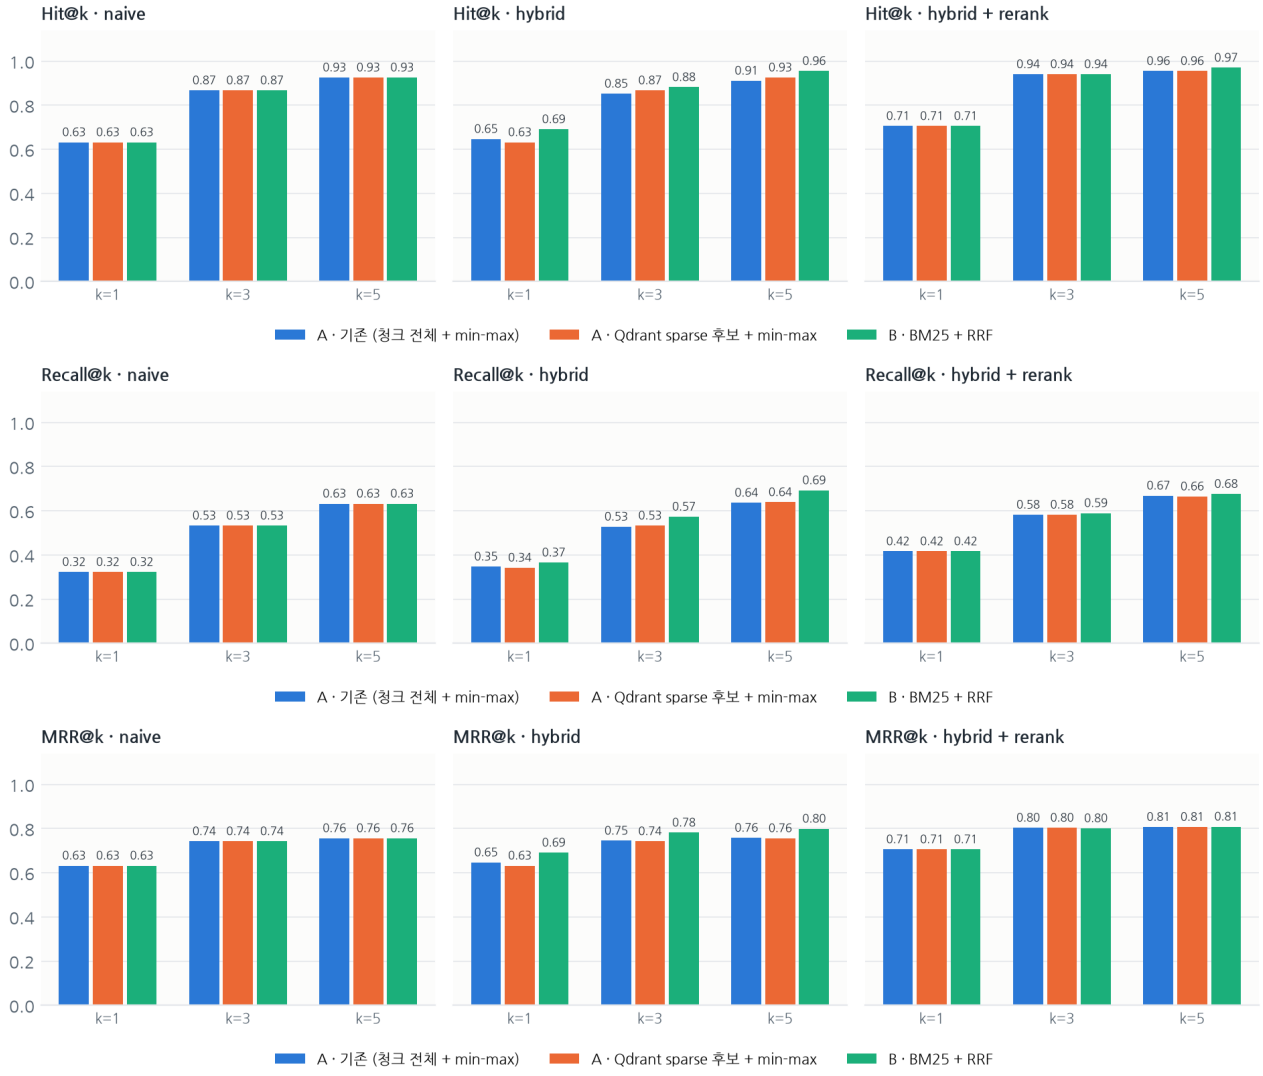
### 검색 성능 (k=5)



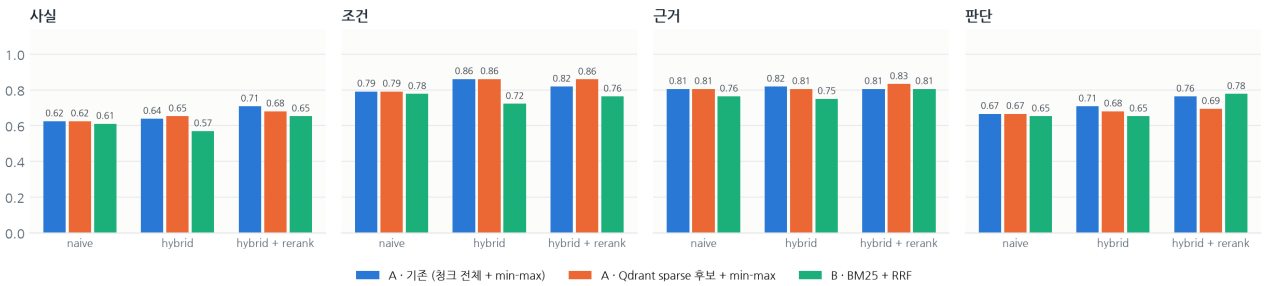
## 검색 지표 전체 (k = 1, 3, 5)

| 구성 · 방식 | Hit@1 | Hit@3 | Hit@5 | Recall@1 | Recall@3 | Recall@5 | MRR@1 | MRR@3 | MRR@5 | 채점 / 제외 |
|---|---|---|---|---|---|---|---|---|---|---|
| A-기존 · naive ※ | 0.632 | 0.868 | 0.926 | 0.323 | 0.533 | 0.632 | 0.632 | 0.743 | 0.757 | 68 / 4 |
| A-기존 · hybrid | 0.647 | 0.853 | 0.912 | 0.347 | 0.528 | 0.636 | 0.647 | 0.745 | 0.758 | 68 / 4 |
| A-기존 · hybrid + rerank | 0.706 | 0.941 | 0.956 | 0.416 | 0.582 | 0.669 | 0.706 | 0.804 | 0.808 | 68 / 4 |
| A-Qdrant · naive | 0.632 | 0.868 | 0.926 | 0.323 | 0.533 | 0.632 | 0.632 | 0.743 | 0.757 | 68 / 4 |
| A-Qdrant · hybrid | 0.632 | 0.868 | 0.926 | 0.342 | 0.533 | 0.639 | 0.632 | 0.743 | 0.757 | 68 / 4 |
| A-Qdrant · hybrid + rerank | 0.706 | 0.941 | 0.956 | 0.416 | 0.582 | 0.665 | 0.706 | 0.804 | 0.808 | 68 / 4 |
| B · naive | 0.632 | 0.868 | 0.926 | 0.323 | 0.533 | 0.632 | 0.632 | 0.743 | 0.757 | 68 / 4 |
| B · hybrid | 0.691 | 0.882 | 0.956 | 0.366 | 0.573 | 0.693 | 0.691 | 0.782 | 0.800 | 68 / 4 |
| B · hybrid + rerank | 0.706 | 0.941 | 0.971 | 0.416 | 0.590 | 0.676 | 0.706 | 0.801 | 0.809 | 68 / 4 |

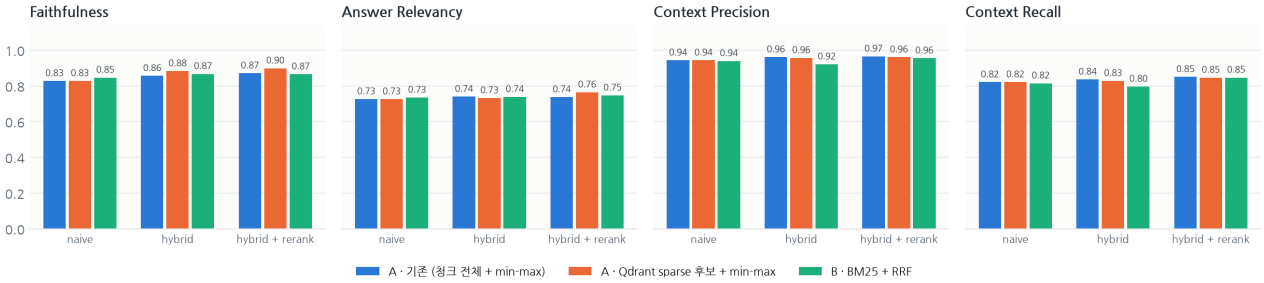
최종 문맥(모델에 들어간 순서)의 상위 k개로 계산했습니다. Hit@k = 참고 문서를 하나라도 찾은 문항 비율, Recall@k = 찾은 참고 문서 수 / 전체 참고 문서 수, MRR@k = 참고 문서가 처음 나온 순위의 역수 평균. '제외'는 근거 문서가 없는 문항(해당 없음)과 서비스 오류 문항 수입니다.



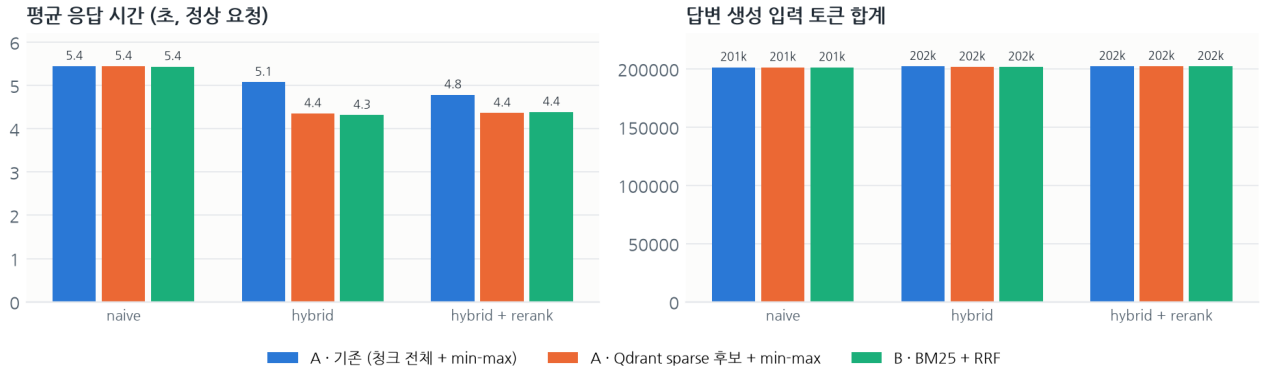
## 답변 품질 · Judge 4항목 (충족률)




## 답변 품질 · RAGAS 4지표 (ragas 라이브러리)




## 운영 지표



## A · 기존 vs A · Qdrant 직접 비교

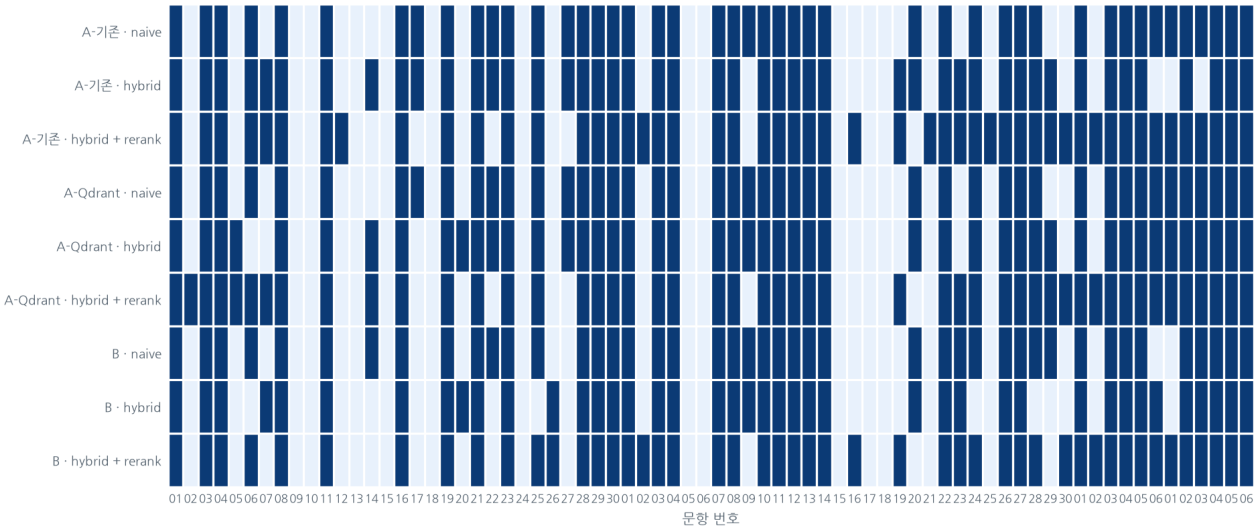
| 방식 | 지표 | A · 기존 | A · Qdrant | 차이 (Q - 기존) | 판정 |
|---|---|---|---|---|---|
| **hybrid** | Hit@5 | 0.912 | 0.926 | +0.015 | 우연 범위 |
| **hybrid** | Recall@5 | 0.636 | 0.639 | +0.002 | 우연 범위 |
| **hybrid** | MRR@5 | 0.758 | 0.757 | -0.002 | 우연 범위 |
| **hybrid** | 사실 | 0.639 | 0.653 | +0.014 | 우연 범위 |
| **hybrid** | 조건 | 0.861 | 0.861 | +0.000 | 우연 범위 |
| **hybrid** | 근거 | 0.819 | 0.806 | -0.014 | 우연 범위 |
| **hybrid** | 판단 | 0.708 | 0.681 | -0.028 | 우연 범위 |
| **hybrid** | Faithfulness | 0.856 | 0.883 | +0.027 | 우연 범위 |
| **hybrid** | Answer Relevancy | 0.740 | 0.732 | -0.008 | 우연 범위 |
| **hybrid** | Context Precision | 0.962 | 0.957 | -0.004 | 우연 범위 |
| **hybrid** | Context Recall | 0.836 | 0.829 | -0.008 | 우연 범위 |
| **hybrid + rerank** | Hit@5 | 0.956 | 0.956 | +0.000 | 우연 범위 |
| **hybrid + rerank** | Recall@5 | 0.669 | 0.665 | -0.004 | 우연 범위 |
| **hybrid + rerank** | MRR@5 | 0.808 | 0.808 | +0.000 | 우연 범위 |
| **hybrid + rerank** | 사실 | 0.708 | 0.681 | -0.028 | 우연 범위 |
| **hybrid + rerank** | 조건 | 0.819 | 0.859 | +0.040 | 우연 범위 |
| **hybrid + rerank** | 근거 | 0.806 | 0.833 | +0.028 | 우연 범위 |
| **hybrid + rerank** | 판단 | 0.764 | 0.694 | -0.069 | 차이 있음 |
| **hybrid + rerank** | Faithfulness | 0.871 | 0.899 | +0.028 | 우연 범위 |
| **hybrid + rerank** | Answer Relevancy | 0.738 | 0.764 | +0.026 | 우연 범위 |
| **hybrid + rerank** | Context Precision | 0.965 | 0.961 | -0.004 | 우연 범위 |
| **hybrid + rerank** | Context Recall | 0.851 | 0.847 | -0.004 | 우연 범위 |

## 운영 지표 표

| 구성 · 방식 | 요청 | 오류 | 오류율 | 평균 응답(초) | 중앙값(초) | 입력 토큰 | 출력 토큰 | 생성 비용($) |
|---|---|---|---|---|---|---|---|---|
| **A-기존 · naive ※** | 72 | 0 | 0% | 5.4 | 3.3 | 201,378 | 16,823 | 0.017 |
| **A-기존 · hybrid** | 72 | 0 | 0% | 5.1 | 3.3 | 202,168 | 16,800 | 0.014 |
| **A-기존 · hybrid + rerank** | 72 | 0 | 0% | 4.8 | 3.5 | 202,234 | 16,398 | 0.011 |
| **A-Qdrant · naive** | 72 | 0 | 0% | 5.4 | 3.3 | 201,378 | 16,823 | 0.017 |
| **A-Qdrant · hybrid** | 72 | 0 | 0% | 4.4 | 3.5 | 201,770 | 17,227 | 0.017 |
| **A-Qdrant · hybrid + rerank** | 72 | 0 | 0% | 4.4 | 3.7 | 202,302 | 16,259 | 0.016 |
| **B · naive** | 72 | 0 | 0% | 5.4 | 3.6 | 201,378 | 16,564 | 0.011 |
| **B · hybrid** | 72 | 0 | 0% | 4.3 | 3.4 | 201,727 | 16,540 | 0.017 |
| **B · hybrid + rerank** | 72 | 0 | 0% | 4.4 | 3.8 | 202,118 | 16,241 | 0.012 |

응답 시간은 평가 스크립트가 잰 질문 → 답변 시간(검색 + 리랭킹 + 생성)이고, 생성 비용은 Langfuse 가격표로 계산한 답변 생성 비용입니다. 서버 evaluator 채점 비용은 포함하지 않습니다. A · 기존은 실행마다 첫 요청에서 청크를 모두 받아 오는 시간(advanced 약 7분)이 앞쪽 문항들의 응답 시간에 섞여 평균이 크게 나올 수 있어, 중앙값을 함께 봅니다.

## 문항별 사실(judge_facts) 지도




진한 파랑 = 충족(1), 연한 색 = 미충족(0), 빗금 = 해당 없음 또는 점수 없음. 열 전체가 연한 문항은 어떤 구성도 못 맞힌 문항이라 검색 방식보다 청킹·프롬프트·정답 해석 쪽을 봐야 합니다.
모든 구성이 사실 0점인 문항 (11개): S-DEV-09, S-DEV-10, S-DEV-13, S-DEV-15, S-DEV-18, S-DEV-24, S-FINAL-05, S-FINAL-06, S-FINAL-15, S-FINAL-17, S-FINAL-18

## 4. 한계

- 질문은 공개된 골든 데이터셋(development·additional·expansion_validation)이라 비공개 테스트 성능으로 볼 수 없습니다.
- 답변 점수는 LLM 채점이라 같은 답변도 실행마다 조금씩 달라질 수 있습니다. 대표 사례는 원문과 대조해야 합니다.
- 검색 지표는 문서 단위입니다. 같은 문서의 다른 쪽을 찾아도 맞은 것으로 셉니다.
- A · 기존과 A · Qdrant의 hybrid는 정규화 범위(전체 vs 후보)가 달라 순위가 조금 다를 수 있습니다. A · Qdrant는 실험 이후 후보 500, 가중치 0.5 : 0.5로 바꿨습니다(1절 표).
- RAGAS는 실험 뒤에 저장된 답변·최종 문맥으로 따로 계산해 올렸습니다(답변은 다시 만들지 않음). 같은 팀 채점 코드(quality.py)를 씁니다.
- Judge는 Langfuse 서버 evaluator가 채점합니다. 해당 없음·평가 불가는 이유 첫머리 표시([해당 없음]·[평가 불가])로 읽어 평균에서 뺍니다(server_judge_summary.py 규칙).