retrieval_b · 최종 문맥 수 k 평가

B 모델(bge-m3 dense + BM25, RRF, 리랭커)에서 LLM에 넣는 최종 청크 수 k를 바꿔 품질 · 토큰 · 속도 · 효율을 비교했습니다.

> **결론 k = 10.** 정답률 0.522로 가장 높고(k5 0.400), 토큰은 k5보다 28% 더 쓰지만 토큰 10만 개당 정답 수는 13.5로 k8(13.5)과 같은 최고 수준입니다. 토큰을 아껴야 하면 k8(정답률 0.478, 토큰 9%), 난이도별로 나눌 수 있으면 basic · intermediate 10, advanced 8.

B 모델 구성

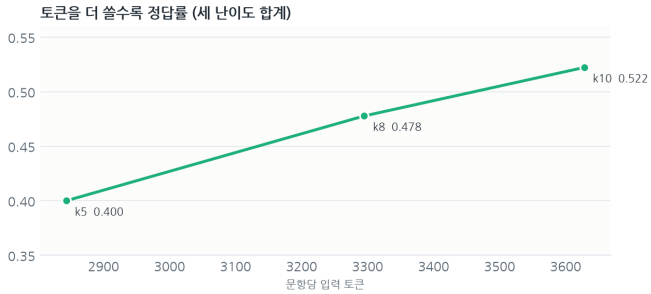
단계	설정
dense 검색	bge-m3, Qdrant kant_shipping_{난이도}_bge-m3, 후보 30개
키워드 검색	BM25 (Kiwi 형태소), 청크를 Qdrant에서 받아 메모리에서 계산, 후보 30개
합치기	RRF: 1/(60 + 순위)를 dense와 BM25에서 1:1로 더함 (가중치 없음)
리랭커	bge-reranker-v2-m3: RRF 상위 50개를 다시 매겨 최종 k개
답변 · 채점	답변 gpt-6-luna, RAGAS 채점 gpt-6-luna + bge-m3 임베딩, Judge는 Langfuse 서버 평가기

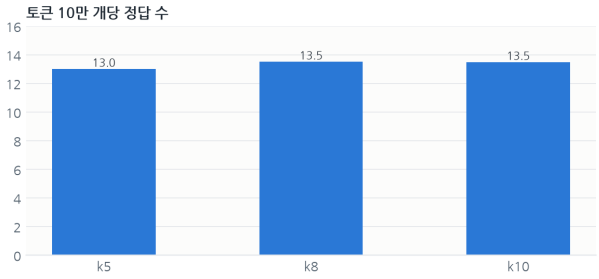
종합 평가 (세 난이도 합계 90문항)

항목	k5	k8	k10
정답률	0.400 (36)	0.478 (43)	**0.522** (47)
Judge 사실 / 결론 / 근거 / 조건	0.46 / 0.47 / 0.66 / 0.59	0.53 / 0.54 / 0.68 / 0.61	0.54 / 0.59 / 0.73 / 0.61
Faithfulness	0.833	0.834	**0.846**
Context Recall	0.719	0.767	**0.778**
Context Precision	**0.887**	0.877	0.845
Answer Relevancy	0.645	**0.698**	0.686
검색 Hit@k / Recall@k	0.93 / 0.60	0.93 / 0.66	0.95 / 0.70
문항당 입력 토큰	**2,843**	3,295	3,628
문항당 출력 토큰	**232**	241	243
응답 시간 중앙값 / 상위 10%	4.6초 / 9.2초	4.8초 / 9.2초	5.1초 / 9.1초
토큰 10만 개당 정답 수	13.0	**13.5**	13.5
답함 / 되묻기 / 보류	58 / 18 / 14	57 / 23 / 10	61 / 16 / 13

굵은 글씨는 그 항목에서 가장 좋은 값(토큰은 가장 적은 값). 정답률 = 서버 Judge 4항목을 모두 통과한 문항 비율, 괄호는 문항 수.

토큰 효율

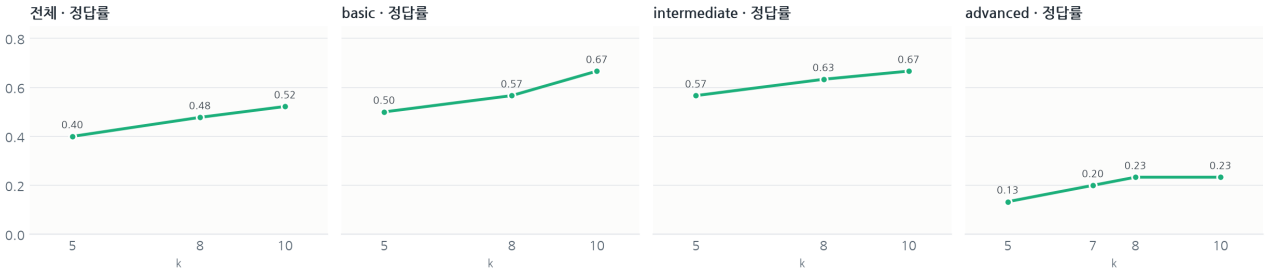




	k5	k8	k10
90문항 총 토큰 (입력 + 출력)	276,768	318,202	348,438
토큰 10만 개당 정답 수	13.0	**13.5**	**13.5**
정답 1개를 더 맞히는 데 든 추가 토큰	(기준)	k5 대비 5,919	k8 대비 7,559
문항 1,000개 처리 시 토큰 (추정)	약 308만	약 354만	약 387만

- **k5는 토큰이 가장 적지만 효율은 가장 낮습니다.** 정답을 놓치는 문항이 많아 토큰당 정답 수가 13.0입니다.
- **k8과 k10은 효율이 같습니다(13.5).** k10은 같은 효율로 정답을 4개 더 맞힙니다.
- 출력 토큰은 k와 관계없이 문항당 230~250개로 거의 같습니다. 늘어나는 것은 문맥으로 들어가는 입력 토큰입니다.
- 비용($)은 Langfuse 서버에 gpt-6-luna 가격이 등록되어 있지 않아 계산하지 않았습니다. 토큰 기준으로 k10은 k8보다 약 10% 비쌉니다.

난이도별 결과



basic

k	정답률	Judge 사실·결론·근거·조건	Faith.	C.Recall	C.Prec.	Ans.Rel.	Hit / Recall @k	입력 토큰	시간 중앙값	10만 토큰당 정답	답함·되묻기·보류
k5	0.500 (15)	0.50 · 0.63 · 0.73 · 0.70	0.887	0.831	0.939	0.760	0.96 / 0.57	2,803	3.5초	16.5	22·4·4
k8	0.567 (17)	0.67 · 0.70 · 0.73 · 0.73	0.863	0.889	0.940	0.794	0.96 / 0.67	3,173	4.3초	16.5	22·6·2
k10	0.667 (20)	0.67 · 0.70 · 0.83 · 0.73	0.905	0.898	0.941	0.783	1.00 / 0.76	3,416	4.4초	18.2	24·4·2

intermediate

k	정답률	Judge 사실·결론·근거·조건	Faith.	C.Recall	C.Prec.	Ans.Rel.	Hit / Recall @k	입력 토큰	시간 중앙값	10만 토큰당 정답	답함·되묻기·보류
k5	0.567 (17)	0.63 · 0.60 · 0.73 · 0.77	0.867	0.811	0.904	0.694	1.00 / 0.74	2,968	4.1초	17.8	23·3·4
k8	0.633 (19)	0.67 · 0.67 · 0.80 · 0.73	0.890	0.828	0.897	0.703	1.00 / 0.78	3,564	4.5초	16.7	21·6·3
k10	0.667 (20)	0.67 · 0.77 · 0.87 · 0.70	0.899	0.849	0.865	0.721	1.00 / 0.80	4,076	5.1초	15.5	23·4·3

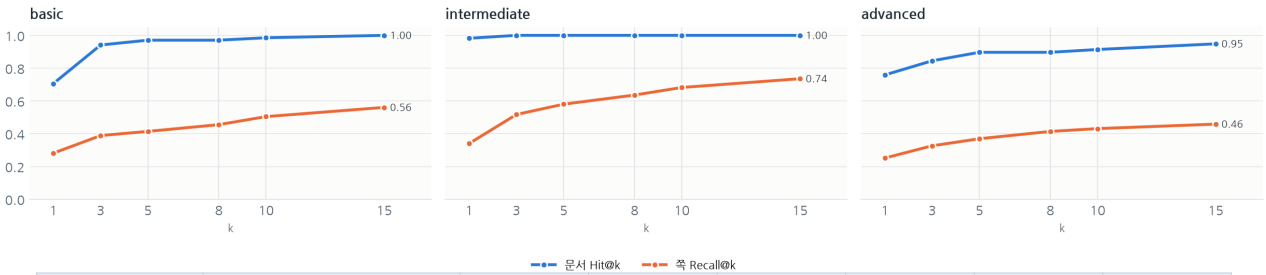
advanced

k	정답률	Judge 사실·결론·근거·조건	Faith.	C.Recall	C.Prec.	Ans.Rel.	Hit / Recall @k	입력 토큰	시간 중앙값	10만 토큰당 정답	답함·되묻기·보류
k5	0.133 (4)	0.23 · 0.17 · 0.50 · 0.30	0.744	0.516	0.818	0.481	0.83 / 0.50	2,760	6.1초	4.4	13·11·6
k7	0.200 (6)	0.30 · 0.23 · 0.57 · 0.30	0.732	0.585	0.799	0.587	0.83 / 0.53	3,016	6.4초	6.1	14·11·5
k8	0.233 (7)	0.27 · 0.27 · 0.50 · 0.37	0.750	0.583	0.793	0.597	0.83 / 0.53	3,148	5.7초	6.9	14·11·5
k10	0.233 (7)	0.30 · 0.30 · 0.50 · 0.40	0.734	0.586	0.728	0.553	0.86 / 0.54	3,391	6.1초	6.4	14·8·8

난이도	정답률 (k5 → k8 → k10)	토큰 10만 개당 정답	최적
basic	0.50 → 0.57 → **0.67**	16.5 → 16.5 → **18.2**	**k10**: 품질 · 효율 모두 최고
intermediate	0.57 → 0.63 → **0.67**	**17.8** → 16.7 → 15.5	품질은 k10, 효율은 k5
advanced	0.13 → (k7 0.20) → **0.23** → 0.23	4.4 → (6.1) → **6.9** → 6.4	**k8**: k10과 정답 수가 같고 토큰은 적음

1단계: 검색만으로 본 k

LLM 없이 검색 결과만 채점했습니다 (난이도별 정답 근거가 있는 전체 문항). 세로선은 2단계에서 답변까지 돌린 k = 5 · 8 · 10.



난이도	구성	k3	k5	k8	k10	k15	검색 시간
basic	후보 30 · 리랭커 50 (현재)	0.94 / 0.39	0.97 / 0.41	0.97 / 0.46	0.99 / 0.50	1.00 / 0.56	0.33초
basic	후보 100 · 리랭커 100	0.94 / 0.39	0.97 / 0.41	0.97 / 0.46	0.99 / 0.50	1.00 / 0.56	0.60초
intermediate	후보 30 · 리랭커 50 (현재)	1.00 / 0.52	1.00 / 0.58	1.00 / 0.64	1.00 / 0.68	1.00 / 0.74	0.58초
intermediate	후보 100 · 리랭커 100	1.00 / 0.51	1.00 / 0.58	1.00 / 0.63	1.00 / 0.64	1.00 / 0.73	1.01초
advanced	후보 30 · 리랭커 50 (현재)	0.84 / 0.33	0.90 / 0.37	0.90 / 0.41	0.91 / 0.43	0.95 / 0.46	1.02초
advanced	후보 100 · 리랭커 100	0.86 / 0.33	0.90 / 0.36	0.91 / 0.41	0.91 / 0.46	0.91 / 0.46	1.36초

값은 문서 Hit@k / 쪽 Recall@k.

- 문서 Hit은 k5에서 거의 꽉 찹니다. 쪽 Recall은 k를 늘릴수록 오르며 k15까지도 계속 오릅니다.
- **후보 수는 지금 값(30 · 50)이 가장 좋습니다.** 100 · 100은 점수가 같거나 낮고 검색 시간만 약 40% 늘어납니다.
- advanced는 정답이 후보 밖에 있는 것이 아니라, 회사 · 날짜만 다른 비슷한 문서와 순위 경쟁에서 밀리는 것이 원인이라 후보를 늘려도 좋아지지 않습니다.

읽을 때 주의할 점

- 난이도마다 30문항이라 1문항이 0.033입니다. 같은 advanced k5를 두 번 돌렸을 때 4문항과 5문항으로 1문항 차이가 났습니다. 판단은 세 난이도 합계(90문항)를 기준으로 했고, k5와 k10의 차이는 11문항, k8과 k10은 4문항입니다.
- k5의 basic · intermediate는 오전 비교 실험, advanced는 저녁에 다시 돌린 실험입니다. 오전 advanced k5(5/30)를 쓰면 합계 정답률은 0.411입니다.
- 응답 시간 평균(8~10초)이 중앙값(5초)보다 큰 것은 advanced 몇 문항이 Qdrant 재시도로 30초 넘게 걸렸기 때문입니다. k와 관계없으며, retrieval_b에 Qdrant 재시도를 넣으면 줄어듭니다.
- advanced 정답률이 낮은 것(최대 0.23)은 k 문제가 아닙니다. 계산에 필요한 문서 3~4개 중 일부만 찾아 모델이 되묻기 · 보류로 답한 경우가 대부분입니다. 회사명 · 날짜 · 건 번호로 거르는 검색이 필요합니다.

실험 목록 (Langfuse)

난이도	k	실험 이름
basic	k5	b_hybrid_rerank_20261112-1023_cmp
basic	k8	b_hybrid_rerank_20261112-1650_basic-dev-k8-gpt6luna
basic	k10	b_hybrid_rerank_20261112-1711_basic-dev-k10-gpt6luna
intermediate	k5	b_hybrid_rerank_20261112-1035_cmp_intermediate
intermediate	k8	b_hybrid_rerank_20261112-1732_intermediate-dev-k8-gpt6luna
intermediate	k10	b_hybrid_rerank_20261112-1754_intermediate-dev-k10-gpt6luna
advanced	k5	b_hybrid_rerank_20261112-2029_advanced-dev-k5-gpt6luna
advanced	k7	b_hybrid_rerank_20261112-2038_advanced-dev-k7-gpt6luna
advanced	k8	b_hybrid_rerank_20261112-1818_advanced-dev-k8-gpt6luna
advanced	k10	b_hybrid_rerank_20261112-1843_advanced-dev-k10-gpt6luna

Langfuse → Datasets → shipping-{난이도}-development-v1 → Experiments. 실험마다 accuracy_mean, judge_*_mean, RAGAS 평균, tokens_in_mean, latency_median이 실험 점수로 올라가 있습니다.