bge-m3 RAGAS 평가: 답변 품질

bge-m3로 검색한 자료로 gpt-6-luna가 답변을 만들고, RAGAS 기본 지표 4개로 채점했다. 골든 데이터셋 68문항 × 검색 방식 3개. 채점도 gpt-6-luna가 했다.

한 줄 결론 · **Hybrid + Reranker**가 답변이 자료에 가장 충실하고(Faithfulness 0.898) 필요한 내용을 가장 많이 가져왔다(Context Recall 0.820). Answer Relevancy가 0.6대로 낮은 것은 되묻기·보류 답변 때문이고, 실제로 답한 문항만 보면 0.76~0.79다.

Naive

Faithfulness **0.867**
Answer Relevancy **0.647**
Context Precision **0.952**
Context Recall **0.761**

답함 49 · 되물음 11 · 보류 8

Hybrid

Faithfulness **0.878**
Answer Relevancy **0.653**
Context Precision **0.976**
Context Recall **0.773**

답함 48 · 되물음 9 · 보류 11

Answer Relevancy · Context Precision 최고

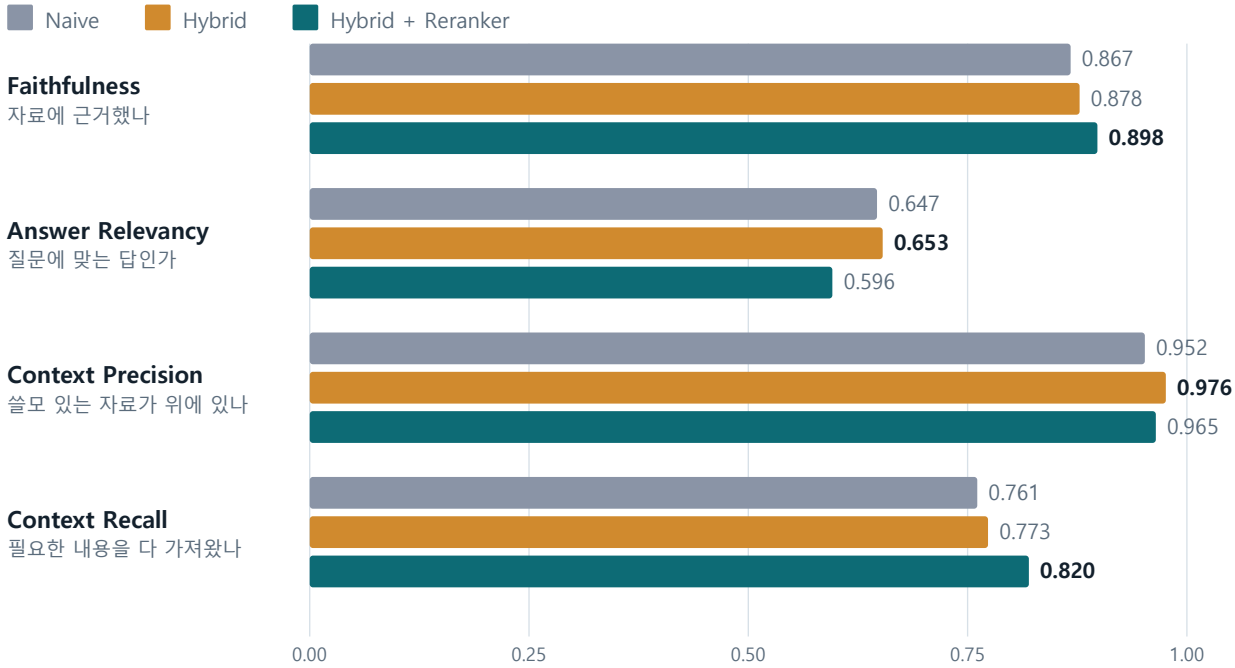
Hybrid + Reranker

Faithfulness **0.898**
Answer Relevancy **0.596**
Context Precision **0.965**
Context Recall **0.820**

답함 50 · 되물음 7 · 보류 11

Faithfulness · Context Recall 최고

네 지표를 막대로 보면



모든 지표는 0~1이고 높을수록 좋다. 진하게 표시된 숫자가 그 지표의 최고값이다.

네 지표는 무엇을 보나

Faithfulness 자료에 근거했나	답변을 문장 단위 주장으로 나눈 뒤, 각 주장이 가져온 자료 5개 안에서 확인되는지 본다. 낮으면 자료에 없는 내용을 지어낸 것이다.
Answer Relevancy 질문에 맞는 답인가	답변만 보고 질문을 거꾸로 3개 만들어, 원래 질문과 얼마나 비슷한지 잰다. 되묻거나 보류한 답변은 질문에 직접 답하지 않아 낮게 나온다.
Context Precision 쓸모 있는 자료가 위에 있나	가져온 자료 5개를 하나씩 정답 답변과 비교해 쓸모 있는지 판정하고, 쓸모 있는 자료가 위쪽에 있을수록 높다.
Context Recall 필요한 내용을 다 가져왔나	정답 답변을 문장으로 나눠, 각 문장의 내용이 가져온 자료에 들어 있는지 본다. 앞의 검색 채점(5위 안에 정답)과 비슷한 지표다.

채점 방식: 답변 생성과 채점 모두 gpt-6-luna, Answer Relevancy의 문장 비교는 내 PC의 bge-m3 임베딩. LLM이 채점하므로 같은 답변을 다시 채점하면 점수가 조금 달라질 수 있다.

Answer Relevancy가 낮은 이유

응답 상태별로 나눠 보면, 실제로 답한 문항은 0.76~0.79인데 보류한 문항은 0~0.2다. 평균이 낮은 것은 답변 품질이 나빠서가 아니라 보류·되묻기가 섞여 있기 때문이다.

모드	응답 상태	문항	Faithfulness	Answer Relevancy	Context Recall
Naive	답함	49	0.871	**0.792**	0.813
	되물음	11	0.848	**0.321**	0.553
	보류	8	0.870	**0.208**	0.729
Hybrid	답함	48	0.897	**0.783**	0.821
	되물음	9	0.850	**0.530**	0.704
	보류	11	0.816	**0.189**	0.621
Hybrid + Reranker	답함	50	0.924	**0.759**	0.867
	되물음	7	0.817	**0.366**	0.750
	보류	11	0.833	**0.000**	0.652

답해야 할 때 답했나

골든 데이터셋에는 문항마다 원하는 행동(답함 / 보류 / 되물음)이 적혀 있다. RAGAS 지표는 이걸 보지 않아서 따로 셌다.

모드	정답지가 원한 행동과 같음	답해야 하는데 보류·되물음	보류해야 하는데 답함
Naive	**55** / 68 (80.9%)	10	2
Hybrid	**51** / 68 (75.0%)	12	3
Hybrid + Reranker	**54** / 68 (79.4%)	10	3

- 답해야 하는 질문을 보류하거나 되물은 경우가 모드마다 10~12문항 있다. 검색이 근거를 놓쳐 LLM이 확신하지 못했을 가능성이 있다(문항별 확인 필요).
- 보류해야 하는 질문(자료에 없는 내용)에 답해 버린 경우도 2~3문항 있다. 지어낸 답이 될 수 있어 주의가 필요하다.

검색 채점과 함께 보면

앞서 정답 근거 문장으로 엄격하게 채점한 검색 결과와 나란히 놓았다. 두 채점 모두 Hybrid + Reranker가 앞선다.

모드	검색 채점: 1등이 정답	검색 채점: 5위 안에 정답	RAGAS: Context Recall	RAGAS: Faithfulness
Naive	9문항	24문항	0.761	0.867
Hybrid	16문항	27문항	0.773	0.878
Hybrid + Reranker	18문항	25문항	0.820	0.898

Context Precision이 0.95 이상으로 높은 것은 RAGAS가 "관련 있는 자료"를 넓게 인정하기 때문이다. 정답 문장이 실제로 들어 있는지는 검색 채점(5위 안에 정답 24~27문항)이 더 엄격하게 보여 준다.

예시: S-DEV-01 "일반 건화물로 예약할 수 있는 컨테이너 종류는?"

모드	답변 (출처 목록 제외)	Faith.	Relev.	Prec.	Recall
Naive	가온루트해운 부산–LA 일반 건화물 안내에서 예약 대상 장비는 **20GP와 40GP**입니다. [S1]에서 부산–로스앤젤레스 항로와 일반 건화물 대상임을 확인하고, [S2]에서 두 컨테이너 종류를 명시합니다. 냉동 컨테이너, 위험물, 규격을 벗어난 화물은 이 안내의 …	0.00	0.88	0.50	1.00
Hybrid	가온루트해운 부산–LA 안내에서 일반 건화물로 예약 대상인 컨테이너는 **20GP와 40GP**입니다. [S1][S2]	1.00	0.98	0.50	1.00
Hybrid + Reranker	일반 건화물로 예약할 수 있는 컨테이너 종류는 20GP와 40GP입니다. [S1]	1.00	0.83	0.83	1.00

Naive 답변은 내용이 맞고 출처도 달았는데 Faithfulness가 0.00으로 나왔다. 채점 LLM이 주장을 제대로 나누지 못한 채점 오류로 보이며, 이런 값이 평균을 조금 끌어내릴 수 있다.

자료에 덜 충실한 답변 (Hybrid + Reranker, 답한 문항 중 하위 6개)

Faithfulness가 낮은 답변은 자료 밖의 내용을 덧붙였을 가능성이 있다. 다만 0.00처럼 극단적인 값은 채점 오류일 수도 있어, 실제 답변을 열어 확인할 대상이다.

ID	Faithfulness	질문
S-FINAL-01	0.00	가온루트해운의 이 안내는 어떤 항로와 화물·장비에 적용하나요?
S-FINAL-02	0.62	부산–LA 예약의 예정 출항일을 11월 6일에서 11월 8일로 바꾸려고 합니다. 예약 변경을 어디에 어떤 내용으로 요청하고, 11월 8일로 변경...
S-FINAL-03	0.75	예약 취소 요청 메일을 보냈습니다. 담당자 회신이 아직 없는데 취소 완료라고 기록해도 될까요?
S-FINAL-13	0.75	2026년 10월 31일 부산–LA 출항용 SI를 작성 중입니다. 포장명세서는 외부 포장 열 상자 안에 제품 백 개라고 되어 있습니다. 새 공지...
S-DEV-10	0.83	같은 40GP 한 대를 쓰되 실제 컨테이너가 교체됐습니다. SI와 반입 예약에는 이전 장비번호를 알렸습니다. 새 번호를 어느 업무에 알려야 하고...
S-FINAL-05	0.83	2026년 11월 1일 부산–LA 출항 예정인 20GP의 SI를 작성합니다. 제출 마감은 언제인가요? 수하인과 착화 통지처를 같은 뜻으로 써도 ...

결론과 다음 단계

- **추천 모드**: Hybrid + Reranker. 답한 문항만 보면 Faithfulness 0.924, Context Recall 0.867로 가장 높다.
- **Answer Relevancy**는 보류·되묻기 때문에 낮게 보이니, 실제로 답한 문항 기준(0.76~0.79)으로 읽는다.
- **개선할 곳**: 답해야 하는데 보류한 문항(10~12개)을 열어 검색이 근거를 놓친 경우인지 확인하고, 그렇다면 질문 나눠 찾기, 후보·결과 수 늘리기로 검색을 보완한다.
- **다음 비교**: Qwen3, bge-m3-bm25로 같은 RAGAS 채점을 돌려 모델 간 답변 품질을 비교한다.

재현 방법과 비용

uv run python -m rag_service.retrieval_a.eval_ragas --profile bge-m3 --golden data/basic/shipping/evaluation/development.json data/basic/shipping/evaluation/additional.json data/basic/shipping/evaluation/expansion_validation.json
결과 폴더: artifacts/retrieval_a/ragas_bge-m3/ (answers_*.jsonl, scores_*.jsonl, per_question.csv, summary.json)
사용 토큰(204회 답변 + 채점): 입력 약 2.6M, 출력 약 0.7M → 약 $0.6~1.3

부록. 문항별 점수 (Hybrid + Reranker)

응답 상태 N / H / R = Naive / Hybrid / Reranker (답 = 답함, 물 = 되물음, 보 = 보류). 0.5 미만 점수는 붉은 칸.

ID	정답지 행동	응답 상태 N / H / R	Faith.	Relev.	Prec.	Recall	질문
S-DEV-01	답함	답 / 답 / 답	1.00	0.83	0.83	1.00	가온루트해운 부산–LA 안내에서 일반 건화물로 예약할 수 있는 컨테이너 종류는 무엇인가...
S-DEV-02	답함	물 / 물 / 보	0.80	0.00	1.00	0.50	가온루트 부산–LA 일반 건화물 40GP로 2026년 11월 6일 출항을 처음 신청하려...
S-DEV-03	답함	답 / 답 / 답	1.00	0.94	1.00	1.00	예약 접수번호를 받았는데 회신에는 검토 중이라고 적혀 있습니다. 이것을 예약 확정으로 ...
S-DEV-04	답함	답 / 답 / 답	1.00	0.96	1.00	1.00	SI의 화물 총중량과 VGM이 다르게 적혀 있으면 어느 하나가 잘못된 건가요? 두 항목...
S-DEV-05	답함	보 / 보 / 보	1.00	0.00	0.95	0.33	가온루트 부산–LA 40GP의 2026년 11월 6일 출항용 SI를 작성 중입니다. 예...
S-DEV-06	답함	물 / 물 / 답	1.00	0.81	0.68	0.50	부산–LA 40GP VGM을 2026년 11월 4일 처음 접수하면서 SI도 제출하려고 ...
S-DEV-07	답함	답 / 답 / 답	0.90	0.75	1.00	1.00	가온루트 예약 확정 확인서만 받았습니다. 그것만 들고 부산 반입센터에 장비를 바로 보내...
S-DEV-08	답함	답 / 답 / 답	1.00	0.85	1.00	1.00	선하증권 초안을 승인했습니다. 고객에게 장비 적재도 완료됐다고 말해도 되나요? 실제 적...
S-DEV-09	답함	물 / 답 / 물	0.71	0.90	0.89	0.25	11월 6일 부산–LA 출항용 SI의 화물 총중량 오기를 발견했습니다. 적용되는 SI ...
S-DEV-10	답함	답 / 답 / 답	0.83	0.80	0.68	0.33	같은 40GP 한 대를 쓰되 실제 컨테이너가 교체됐습니다. SI와 반입 예약에는 이전 ...
S-DEV-11	답함	답 / 답 / 답	1.00	0.79	1.00	1.00	받은 선하증권 파일 이름에 최종이라고 되어 있습니다. 발행 안내는 없고 초안 승인 회신...
S-DEV-13	답함	보 / 보 / 물	0.71	0.00	1.00	0.50	2026년 10월 30일 부산–LA 출항 예정인 20GP입니다. 출항 준비 목록에 SI...
S-DEV-14	답함	보 / 보 / 보	1.00	0.00	1.00	0.50	부산–LA 40GP 한 대의 SI와 VGM을 준비 중입니다. 포장명세서에는 스무 상자 ...
S-DEV-15	답함	답 / 답 / 답	1.00	0.85	1.00	1.00	서류 점검 중 두 오류를 발견했습니다. 40GP VGM은 11월 2일 이메일로 접수했고...
S-DEV-16	답함	답 / 답 / 답	0.86	0.92	0.95	1.00	11월 6일 예정 출항의 SI를 11월 4일 낮 12시까지 내라고 들었습니다. 그러면 ...
S-DEV-17	답함	물 / 답 / 답	1.00	0.00	1.00	1.00	부산–LA 선하증권 초안을 검토 중입니다. 도착지 영문 표기와, 착화 통지처가 수하인과...
S-DEV-18	답함	답 / 물 / 답	1.00	0.82	1.00	0.50	선하증권 초안을 대조하다가 수하인 주소 오류와 중량 기재 의문을 찾았습니다. 포장명세서...
S-DEV-19	답함	답 / 답 / 답	1.00	0.84	1.00	1.00	포장명세서의 순중량, 화물 총중량, VGM은 각각 어디까지 포함하는 건가요?
S-DEV-20	답함	답 / 답 / 답	0.86	0.94	1.00	1.00	선하증권 초안의 수하인 주소만 고치려 합니다. 정정 메일에 어떤 정보를 적어 보내야 하...
S-DEV-21	답함	답 / 답 / 답	1.00	0.87	1.00	1.00	운송사가 부산 센터에 도착했다고 연락했습니다. 반입 완료로 기록해도 되나요? 완료를 확...
S-DEV-22	답함	답 / 답 / 답	0.86	0.81	1.00	1.00	예정 출항일이 지난 예약의 실제 출항 여부와 선하증권 발행본 재송부를 한꺼번에 문의받았...
S-DEV-23	보류	답 / 답 / 답	1.00	0.84	1.00	1.00	이 부산–LA 일반 건화물 안내만으로 냉동 컨테이너도 같은 절차로 예약 가능하다고 확답...
S-DEV-24	답함	답 / 답 / 답	1.00	0.80	1.00	0.50	담당자 인계 메모에서 SI 검토 완료와 반입 상태를 한 줄로 완료라고 적으려 합니다. ...
S-DEV-25	답함	답 / 답 / 보	1.00	0.00	0.53	1.00	2026년 11월 4일 20GP VGM을 처음 내고 SI 정정도 보내려고 합니다. 두 ...
S-DEV-26	답함	답 / 답 / 답	1.00	0.54	1.00	0.50	고객 문의 메모에는 11월 6일 출항 건에 예전 SI 오후 3시 안내를 보았다고 적혀 ...
S-DEV-28	보류	보 / 보 / 보	0.33	0.00	1.00	1.00	가온루트의 제 40GP는 11월 6일 출항 예정이었습니다. 현재 가진 것은 예약 확정 ...
S-DEV-29	되물음	물 / 물 / 물	1.00	0.84	1.00	1.00	포장명세서에 수량 20이라고만 적혀 있습니다. SI 포장 수량에 20상자라고 쓰면 되나...
S-DEV-30	보류	보 / 보 / 보	0.67	0.00	1.00	1.00	SI를 늦게 제출했을 때 무료기간이나 보관료가 얼마나 바뀌는지 이 안내로 계산해 주세요...

ID	정답지 행동	응답 상태 N / H / R	Faith.	Relev.	Prec.	Recall	질문
S-FINAL-01	답함	답 / 답 / 답	0.00	0.90	1.00	1.00	가온루트해운의 이 안내는 어떤 항로와 화물·장비에 적용하나요?
S-FINAL-02	답함	답 / 물 / 답	0.62	0.85	1.00	0.67	부산–LA 예약의 예정 출항일을 11월 6일에서 11월 8일로 바꾸려고 합니다. 예약 …
S-FINAL-03	답함	답 / 답 / 답	0.75	0.82	1.00	1.00	예약 취소 요청 메일을 보냈습니다. 담당자 회신이 아직 없는데 취소 완료라고 기록해도 …
S-FINAL-04	답함	답 / 답 / 답	1.00	0.89	1.00	1.00	SI에 적는 수하인과 착화 통지처는 같은 항목인가요? 통지처에 이름이 있으면 화물을 받…
S-FINAL-05	답함	답 / 답 / 답	0.83	0.00	1.00	0.00	2026년 11월 1일 부산–LA 출항 예정인 20GP의 SI를 작성합니다. 제출 마감…
S-FINAL-06	답함	물 / 보 / 물	0.69	0.83	1.00	0.50	부산–LA 20GP의 VGM을 11월 5일 처음 제출하고 SI 중량 정정도 보내려고 합…
S-FINAL-07	답함	답 / 답 / 답	0.86	0.87	1.00	1.00	예약 확인서에는 40GP 한 대가 확정되어 있습니다. 별도의 반입 회신은 못 받았는데 …
S-FINAL-08	답함	답 / 답 / 답	1.00	0.93	1.00	1.00	LA 도착 예정 안내를 받았습니다. 이 안내만으로 실제 도착과 화물 인도가 승인된 것으…
S-FINAL-09	답함	답 / 답 / 보	0.83	0.00	1.00	0.00	부산–LA 40GP의 적입 후 봉인번호가 바뀌었습니다. SI와 반입 예약에는 옛 번호가…
S-FINAL-10	답함	답 / 답 / 답	1.00	0.84	1.00	1.00	11월 2일 이메일로 접수 완료된 40GP VGM을 11월 5일 정정합니다. 정정일이 …
S-FINAL-11	답함	답 / 답 / 답	1.00	0.95	1.00	1.00	선하증권 초안을 받은 담당자가 파일 잘 받았습니다라고 회신했습니다. 그 답을 초안 승인…
S-FINAL-13	답함	답 / 물 / 답	0.75	0.77	1.00	1.00	2026년 10월 31일 부산–LA 출항용 SI를 작성 중입니다. 포장명세서는 외부 포…
S-FINAL-14	답함	답 / 답 / 답	0.91	0.91	1.00	0.50	11월 6일 예정 출항 건의 SI 마감이 낮 12시로 당겨졌습니다. VGM과 센터 반입…
S-FINAL-15	답함	물 / 물 / 답	0.88	0.81	1.00	0.67	포장명세서의 화물 총중량 오류를 고쳤고 SI도 수정하려고 합니다. 같은 40GP의 VG…
S-FINAL-16	답함	답 / 보 / 답	0.93	0.79	0.68	1.00	실제 컨테이너가 다른 40GP 한 대로 교체됐습니다. 예약 종류·대수·출항일은 그대로입…
S-FINAL-17	답함	답 / 답 / 보	0.73	0.00	1.00	0.33	40GP VGM을 11월 4일 포털에 신규 접수했는데 다음 날 값을 정정하려 합니다. …
S-FINAL-18	답함	물 / 답 / 답	0.88	0.83	1.00	0.50	예약의 예정 출항일을 10월 30일에서 11월 6일로 바꾸려고 합니다. SI 날짜만 고…
S-FINAL-19	답함	답 / 답 / 답	1.00	0.93	1.00	1.00	초안의 착화 통지처 담당자 이메일만 바꾸려고 합니다. 수하인 회사도 바뀐 것으로 적어야…
S-FINAL-20	답함	답 / 답 / 보	0.80	0.00	1.00	0.50	SI에 포장명세서 내용을 옮기고 있습니다. 포장 수량 칸에 제품 수량을 넣어도 되는지와…
S-FINAL-21	답함	답 / 답 / 답	1.00	0.73	1.00	0.50	다른 담당자에게 초안 정정 중인 예약을 넘깁니다. 문서 판본과 실제 운송 상태를 혼동하…
S-FINAL-22	답함	답 / 답 / 답	1.00	0.83	1.00	1.00	반입 완료 기록은 받았는데 적재·출항 안내는 없습니다. 고객에게 출항 완료라고 말할 수…
S-FINAL-23	보류	보 / 보 / 보	1.00	0.00	1.00	1.00	수하인에게 선하증권 발행본이 있다고 합니다. 이 안내만 보고 그 사람이 LA에서 화물을…
S-FINAL-24	답함	답 / 답 / 답	1.00	0.84	0.68	1.00	40GP VGM은 11월 2일 이메일 접수가 끝났습니다. 11월 4일 새 공지를 보고 …
S-FINAL-25	답함	답 / 답 / 답	1.00	0.78	0.92	1.00	고객 문의 메모의 10월 30일 예정 출항 사례는 새 공지 발행 뒤니까 SI를 낮 12…
S-FINAL-26	답함	답 / 답 / 답	1.00	0.62	0.92	1.00	신규 40GP VGM은 포털이라고 들었습니다. SI 최초 제출과 SI 정정도 포털로 바…
S-FINAL-27	되물음	물 / 물 / 물	0.60	0.00	0.89	1.00	부산–LA 40GP VGM은 11월 4일 제출하려고 합니다. 해당 예약 확정 안내는 지…
S-FINAL-28	보류	보 / 보 / 답	1.00	0.00	1.00	1.00	제 예약 장비가 센터에 도착했다는 운송사 연락만 있습니다. 현재 반입 완료됐는지 확정해…
S-FINAL-30	보류	보 / 물 / 보	1.00	0.00	1.00	1.00	반입이 지연될 것 같습니다. 이 절차 안내만으로 하루 늦으면 얼마를 부담하는지 산출해 …
S-VAL-DEV-01	답함	답 / 답 / 답	0.86	0.85	1.00	1.00	예약 업무 안내의 GR01-310·GR01-311 대수 변경 상담 사례입니다. GR01…
S-VAL-DEV-02	답함	답 / 보 / 답	1.00	0.75	1.00	0.50	장비 인수 안내의 GRB02-517 사례처럼 예약은 20GP 한 대인데 운송사가 다른 …

ID	정답지 행동	응답 상태 N / H / R	Faith.	Relev.	Prec.	Recall	질문
S-VAL-DEV-03	보류	답 / 답 / 물	1.00	0.00	1.00	1.00	서류 제출 안내의 GR03-533 사례에서 SI 정정 메일 본문은 봉인번호 변경이라고 …
S-VAL-DEV-04	답함	답 / 답 / 답	0.90	0.80	1.00	0.67	부산 반입센터의 BR04-5608 부분 반입 사례입니다. 반입운영팀 회신에는 GRTU2…
S-VAL-DEV-05	답함	답 / 답 / 답	0.87	0.78	1.00	1.00	선하증권 안내의 GR05-PA882 사례에서 화주는 초안 2판의 수하인 주소는 맞고 포…
S-VAL-DEV-06	보류	물 / 답 / 답	1.00	0.00	1.00	1.00	출항 이후 안내의 GR06-418 사례입니다. 적재 여부를 문의했는데 회신에는 GR06…
S-VAL-FINAL-01	되물음	물 / 보 / 물	1.00	0.00	1.00	1.00	SI 작성 안내의 GR07-641 사례처럼 같은 화물 총중량이 포장명세서에는 1,240…
S-VAL-FINAL-02	답함	답 / 답 / 답	0.83	0.85	1.00	1.00	VGM 안내의 GR08-563 사례처럼 책임자 이름만 있고 연락처가 빠졌습니다. 예약 …
S-VAL-FINAL-03	답함	답 / 답 / 답	1.00	0.78	1.00	1.00	첨부자료 대조 안내의 GR09-620에는 2 pallets / 24 cartons가 함…
S-VAL-FINAL-04	답함	답 / 답 / 답	1.00	0.76	1.00	1.00	초안 항목별 확인 메모를 따라 품명·포장 수량, 출발·도착 항로, 장비·봉인번호를 각각…
S-VAL-FINAL-05	답함	답 / 답 / 답	1.00	0.82	1.00	1.00	변경 공지의 GR11-721 연습 사례는 20GP와 40GP 한 대씩의 VGM을 202…
S-VAL-FINAL-06	답함	답 / 답 / 답	1.00	0.70	1.00	1.00	마감 문의 FAQ의 시간대 누락 사례입니다. 11월 6일 예정 출항으로 확정된 예약의 …