평가 지표 안내서

검색 지표 · 답변 지표(RAGAS, LLM-as-a-Judge) · 운영 지표, 그리고 실행 방법

kant-rag 팀 · 2026-11-11 · 기준 코드: evaluation/langfuse_experiment.py

> **기준** 이 문서는 검색 평가 구현(evaluation/retrieval/retrieval_scores.py)과 retrieval_a·b 비교 옵션(--impl)이 들어간 코드 기준입니다. 두 변경이 main에 반영되기 전이라면 검색 점수와 --impl 옵션이 없을 수 있습니다.

1. 한눈에 보기

평가는 **같은 질문을 여러 RAG 구성에 똑같이 던지고**, 나온 결과를 같은 기준으로 채점해 비교하는 일입니다. 우리 팀은 검색기 구현 2개와 검색 방식 3개를 곱한 **6개 구성**을 비교합니다.

	naive	hybrid	hybrid_rerank
retrieval_a	bge-m3 벡터 검색	bge-m3 벡터 + bge-m3 sparse, min-max 가중합(0.7 / 0.3)	hybrid 후보 50개를 bge-reranker-v2-m3로 재정렬
retrieval_b	bge-m3 벡터 검색	bge-m3 벡터 + BM25(Kiwi), RRF(k=60)	hybrid 후보 50개를 bge-reranker-v2-m3로 재정렬

여섯 구성 모두 같은 질문, 같은 답변 프롬프트, 같은 생성 모델(gpt-6-luna), 같은 최종 청크 수(k=5), 같은 채점 모델을 씁니다. 그래서 점수 차이는 **검색 구성의 차이**로 읽을 수 있습니다.

지표는 네 묶음입니다

묶음	묻는 질문	지표 (Langfuse 점수 이름)	LLM 비용
검색	맞는 문서를 찾아왔나?	hit_at_5, recall_at_5, mrr_at_5	없음
답변: RAGAS	문맥에 근거했나? 질문에 맞나? 문맥이 좋았나?	faithfulness, answer_relevancy, context_precision, context_recall	있음
답변: Judge	사실·조건·근거·판단이 기준에 맞나?	judge_facts, judge_conditions, judge_evidence, judge_decision	있음
운영	얼마나 빠르고, 얼마나 실패하고, 얼마나 쓰나?	응답 시간, 오류율, 토큰 사용량	없음 (측정만)

문항 하나가 지나가는 길

```
Langfuse 데이터셋 문항 (질문 + 정답 칸)
  | 질문만 넘김 (정답은 채점 때만 사용)
  v
팀 chain(create_chain) 실행 -> 답변, 상태, 인용, 실제 최종 문맥(contexts), 응답 시간 기록
  |
  +-- answer_quality      (evaluation/answer/quality.py)      RAGAS 4개 + Judge 4항목
  +-- retrieval_judgement (evaluation/retrieval/retrieval_scores.py) Hit / Recall / MRR
  v
Langfuse에 문항별 점수 저장 -> 실행이 끝나면 지표별 평균(<이름>_mean)과 건수 저장
```

2. 모든 지표에 공통인 규칙: 점수 상태

점수를 매길 수 없는 경우를 **0점으로 바꾸지 않는 것**이 핵심입니다. 모든 점수는 아래 세 상태 중 하나입니다.

상태	뜻	평균에	예
scored	점수가 있음	넣음 (0점도 넣음)	Hit@5 = 0, faithfulness = 0.83
na (해당 없음)	채점할 대상 자체가 없음	빼고 건수만 셈	근거 문서가 없는 보류 문항의 Hit@5, 사실 주장 없이 되묻기만 한 답의 faithfulness
unavailable (평가 불가)	대상은 있는데 채점을 못 함	빼고 건수만 셈	서비스 오류, 정답 파일에 없음, 채점 호출 실패

Langfuse에는 scored면 숫자 점수(예: **hit_at_5** = 1)로, 아니면 **<이름>_state** = na 또는 unavailable로 올라가고, comment에 사유(cause)와 이유가 남습니다. 실행 요약의 **<이름>_mean** comment에는 "평가 대상 / 해당 없음 / 평가 불가" 건수와 답변·되묻기·보류별 평균이 함께 적힙니다.

> **읽는 법** 평균만 보지 말고 평가 대상 수를 같이 보세요. 30문항 중 평가 대상이 12개뿐인 평균은 30개 평균과 무게가 다릅니다.

3. 검색 지표: 맞는 문서를 찾아왔나?

검색 지표는 LLM 없이 계산합니다. 정답 파일의 **evidence_groups**에 적힌 근거 문서와, 모델에 실제로 들어간 **최종 문맥 상위 k개**의 문서를 비교합니다(발제 STEP 6 기준).

- **참고 문서**: evidence_groups에 등록된 모든 book_id를 모아 중복을 뺀 목록 (예: SB01, SB03)
- **찾은 문서**: 최종 문맥 상위 k개(기본 5개)의 book_id. 같은 문서의 청크가 여러 개 나와도 한 번만 셉니다
- 쪽(page)이나 문장까지는 보지 않습니다. **문서 단위**로 맞았는지만 봅니다

지표	쉬운 설명	계산	범위
Hit@k (hit_at_5)	참고 문서를 하나라도 찾았나?	하나라도 찾으면 1, 아니면 0	0 또는 1
Recall@k (recall_at_5)	참고 문서를 얼마나 빠짐없이 찾았나?	찾은 참고 문서 수 ÷ 전체 참고 문서 수	0 ~ 1
MRR@k (mrr_at_5)	참고 문서가 얼마나 위에 나왔나?	참고 문서가 처음 나온 순위 r의 1/r (없으면 0)	0 ~ 1

예시

참고 문서가 A, B이고, 최종 문맥 상위 5개의 문서가 [C, A, A, D, E]라면

- Hit@5 = **1** (A를 찾음)
- Recall@5 = **0.5** (A, B 중 A만 찾음. A가 두 번 나와도 한 번만 셈)
- MRR@5 = **0.5** (참고 문서 A가 처음 나온 곳이 2위 → 1/2)

> **주의** Recall 0.5가 "답변이 절반만 맞았다"는 뜻은 아닙니다. A와 B가 같은 사실을 설명한다면 A만으로도 충분히 정답을 쓸 수 있습니다. 답변이 맞았는지는 아래 답변 지표로 따로 봅니다.

상태 규칙

상황	기록
서비스 오류로 검색 결과를 알 수 없음	평가 불가 (service_error)
정답 파일에 없는 문항	평가 불가 (no_golden)
evidence_groups가 비어 있음 (보류·되묻기 문항 등)	해당 없음 (no_evidence)
검색 결과가 비었지만 참고 문서는 있음	0점 (평균에서 빼지 않음)

4. 답변 지표 ① RAGAS

RAGAS는 LLM을 채점자로 써서 답변과 문맥을 자동 채점하는 라이브러리입니다(ragas 0.4.3). 모두 0~1 점수이고, 높을수록 좋습니다. 채점 모델은 gpt-6-luna, answer_relevancy의 유사도 계산에는 bge-m3 임베딩을 씁니다.

지표	쉬운 질문	어떻게 계산하나	정답 사용
faithfulness (충실성)	답변이 문맥에 없는 말을 지어내지 않았나?	답변을 짧은 주장들로 나누고, 각 주장이 실제 최종 문맥에서 확인되는 비율	안 씀
answer_relevancy (답변 관련성)	질문에 맞는 답인가?	답변만 보고 질문을 거꾸로 만들어 본 뒤, 원래 질문과 얼마나 비슷한지(임베딩 유사도)	안 씀
context_precision (문맥 정밀도)	쓸모 있는 문맥이 위쪽에 있나?	문맥 하나하나가 참고 정답에 도움이 되는지 판정하고, 위쪽에 있을수록 더 큰 가중치	씀
context_recall (문맥 재현율)	정답에 필요한 내용을 문맥이 다 담았나?	참고 정답을 주장들로 나누고, 각 주장이 문맥에서 확인되는 비율	씀

상태 규칙

지표	평가 불가 (unavailable)	해당 없음 (na)
faithfulness	서비스 오류, 빈 답변, 빈 문맥, 채점 실패	답변에 사실 주장이 없음
answer_relevancy	서비스 오류, 빈 답변, 채점 실패	없음 (되묻기·보류도 채점)
context_precision	서비스 오류, 빈 문맥, 정답 파일에 없음, 채점 실패	참고 정답(reference_answer)이 빔
context_recall	서비스 오류, 빈 문맥, 정답 파일에 없음, 채점 실패	참고 정답이 빔, 정답을 주장으로 못 나눔

읽는 법 answer_relevancy는 "확인이 필요합니다" 같은 되묻기·보류 답변에서 낮게 나오기 쉽습니다. 실행 요약의 답변·되묻기·보류별 평균을 따로 보세요.

5. 답변 지표 ② LLM-as-a-Judge

평가 LLM에게 **참고 정답과 채점 기준**을 주고 네 항목을 각각 1(충족) 또는 0(미충족)으로, 짧은 이유와 함께 채점하게 합니다. 참고 정답과 문장이 같을 필요는 없고, 문맥에서 확인되는 충분한 대체 근거도 인정합니다.

항목 (점수 이름)	1로 기록하는 기준	0이 되는 예
사실 (judge_facts)	필요한 사실과 수치를 정확히 제시하고 빠뜨리지 않음	수치가 틀림, 필수 사실 누락, 금지 주장을 함
조건 (judge_conditions)	회사, 모델, 기간, 단위, 정정과 적용 범위가 맞음	정정 전 구판 값을 답함, 다른 회사 기준을 씀
근거 (judge_evidence)	중요한 주장에 실제 최종 문맥의 근거가 있고, 인용한 쪽이 주장을 뒷받침함	인용한 쪽에 그 내용이 없음

항목 (점수 이름)	1로 기록하는 기준	0이 되는 예
판단 (judge_decision)	답변 / 추가 확인 / 보류의 선택과 이유가 질문과 근거에 맞음	근거가 없는데 단정, 답할 수 있는데 보류

- Judge에 들어가는 것: 질문, 생성 답변, 상태, 인용, 실제 최종 문맥, 참고 정답, 필수 사실, 금지 주장, 기대 동작, 채점 설명
- 평가할 대상이 없는 항목(예: 문서 내용 없이 되묻기만 한 답의 사실·근거)은 null → **해당 없음**. 필요한 사실을 빠뜨린 건 해당 없음이 아니라 **0**
- 판단은 항상 0 또는 1. 서비스 오류로 답을 못 만들면 판단 = 0, 나머지 셋은 평가 불가
- 항목별 충족률 = 1을 받은 답변 수 ÷ 그 항목의 평가 대상 수. 네 항목을 하나로 합산하지 않습니다

> **왜 둘 다 보나** 구판 문서의 "10분"을 그대로 답하면 문맥을 잘 따랐으므로 faithfulness는 높습니다. 하지만 질문에 적용되는 정정 값이 "15분"이면 Judge의 사실·조건은 0입니다. faithfulness는 **문맥에 근거했는지**, Judge는 **질문에 맞게 답했는지**를 봅니다.

6. 운영 지표: 얼마나 빠르고, 얼마나 실패하고, 얼마나 쓰나?

지표	뜻	어디서 보나
응답 시간	질문을 넣은 때부터 답이 나올 때까지(검색 + 리랭킹 + 생성)	문항 기록의 latency_ms, Langfuse trace의 시간
오류율	재시도 후에도 시스템 오류로 끝난 요청 수 ÷ 전체 요청 수 × 100 (건수도 함께)	문항 기록의 status = "error"와 error 메시지
서비스 토큰	답변을 만들 때 쓴 입력·출력 토큰	Langfuse의 chain trace (모델 호출별)
채점 토큰	RAGAS·Judge 채점에 쓴 토큰. 서비스 토큰과 섞지 않음	실행 점수 grading_tokens_input, grading_tokens_output

- 되묻기·보류는 정상 응답입니다. 오류 건수에 넣지 않습니다
- 측정하지 못한 값은 0이 아니라 "확인 불가"로 적습니다

7. 실행 방법

7-1. 준비 (한 번만)

- 레포 맨 위 폴더(kant-rag)에서 가상환경을 켭니다
- .env에 OPENAI_*, LANGFUSE_*, QDRANT_* 값이 있어야 합니다
- Langfuse 데이터셋은 이미 올라가 있습니다: shipping-{basic, intermediate, advanced}-{development, additional}-v1 (각 30문항)
- GPU를 쓰는 다른 작업은 멈춥니다. 노트북 GPU(8GB)에서 메모리가 부족하면 리랭커 단계에서 실패합니다

```
.venv/Scripts/activate
$env:PYTHONIOENCODING="utf-8"      # 한글 출력 깨짐 방지
```

7-2. 실행

```
# ① 먼저 2문항, 한 방식으로 시험 (비용·설정 확인)
python evaluation/langfuse_experiment.py --impl retrieval_a --modes hybrid_rerank --limit 2

# ② 본 실행: 구현마다 세 방식 x development 30문항. a와 b는 동시에 말고 차례로
python evaluation/langfuse_experiment.py --impl retrieval_a
python evaluation/langfuse_experiment.py --impl retrieval_b

# 다른 난이도·분할
python evaluation/langfuse_experiment.py --impl retrieval_a --difficulty advanced --split additional
```

옵션	기본값	뜻
--impl	retrieval_a	검색기 구현: retrieval_a 또는 retrieval_b
--modes	세 방식 모두	naive / hybrid / hybrid_rerank 중 여러 개
--difficulty	basic	basic / intermediate / advanced
--split	development	development / additional / expansion_validation
--limit	0 (전부)	앞에서 N문항만
--k	5	검색 지표의 k
--no-retrieval		검색 지표는 빼고 답변 지표만
--page-context		찾은 청크 대신 그 쪽(page) 전체를 문맥으로
--model	gpt-6-luna	채점 LLM (모든 구성에 같게)
--tag		실행 이름 끝에 붙일 말 (실험 구분용)

7-3. 결과 보기

- **Langfuse 웹**: Datasets → 데이터셋(예: shipping-basic-development-v1) → Runs. 실행 이름은 retrieval_a가 **hybrid_rerank_20261111-1530**처럼, retrieval_b는 앞에 **b_**가 붙습니다
- Runs 표에서 구성별 평균(**hit_at_5_mean**, **faithfulness_mean**, **judge_facts_mean** …)을 나란히 비교합니다
- 문항을 누르면 점수와 이유, 그리고 trace(검색 결과, 모델 입력·출력, 시간, 토큰)를 볼 수 있습니다. 발제 STEP 7의 "요청 ID로 실행 기록 연결"이 이것입니다
- **로컬 사본**: results/langfuse/{실행 이름}.json (요약, 채점 토큰, Langfuse 링크). results/는 커밋하지 않습니다
- **터미널**: 실행이 끝날 때마다 지표별 평균과 건수 표가 출력됩니다

7-4. 검색만 빠르게 보고 싶을 때 (LLM 비용 없음)

리랭커나 임베딩 같은 **모델 후보**를 고를 때는 retrieval_a의 로컬 검색 평가 스크립트가 빠릅니다.
config/retrieval_a/models.yaml의 프로필 이름을 --profile로 고릅니다.

```
python -m rag_service.retrieval_a.eval_retrieval `
  --golden data/basic/shipping/evaluation/development.json `
  --profile bge-m3 --modes naive hybrid rerank --out artifacts/retrieval_a/eval_check
```

주의 이 스크립트의 Hit@k·MRR은 정답 **문장**이 청크에 들어 있는지로 계산하고 Recall@k가 없습니다. 발제 기준(문서 단위)과 다르므로 보고서 숫자는 langfuse_experiment.py의 hit_at_5 / recall_at_5를 쓰세요.

7-5. 자주 막히는 곳

증상	원인과 해결
Cannot find the requested files in the disk cache	eval 스크립트가 오프라인 모드로 돈다. 새 모델은 snapshot_download로 먼저 받아 둔다
CUDA out of memory	다른 GPU 작업이 메모리를 쓰는 중이거나 a·b를 동시에 실행. 하나씩 실행한다
advanced가 시작에서 오래 멈춤	hybrid가 Qdrant에서 청크 약 9만 개를 받는 중(약 7분). 정상
Server disconnected (Qdrant)	일시적 끊김. hybrid가 자동으로 3번까지 재시도한다. 계속되면 QDRANT_URL과 서버 상태 확인
점수가 모두 _state = unavailable	comment의 cause 확인: service_error(답변 실패), grading_failed(채점 호출 실패), no_golden(정답 없음)

8. 결과를 읽을 때 체크리스트

- 평균 옆의 **평가 대상 수, 해당 없음, 평가 불가, 오류 건수**를 같이 적었나?
- 30문항 기준 1문항 = 약 0.033. 0.03 안팎의 차이는 우연일 수 있다
- 검색 점수가 좋아졌는데 답변 점수가 그대로면 → 프롬프트·생성 쪽, 검색 점수부터 나쁘면 → 검색·청킹 쪽
- 평균이 올라도 **나빠진 문항**이 있으면 원문과 대조해 이유를 적는다 (실패한 실행도 빼지 않는다)
- 대표 사례 몇 개는 Judge의 이유를 사람이 원문과 대조하고, 자동 채점이 틀렸으면 원래 점수와 수정 이유를 함께 남긴다
- 품질이 비슷하면 응답 시간과 토큰을 함께 보고 최종 구성을 고른다